MODEL · PHYSICS · GPU · EVIDENCE

Symmetrix-Polar

从模型原理到 GPU 优化

中文教程与测试解读

从原子、能量和力出发，逐步理解 MACE、PolarMACE、
长程静电、GPU 执行与本项目的性能证据。

Yong-Q 项目资料 · 基于已提交记录重新核对

2026-10-21

性能统一为 μs/atom/step · 数学公式为矢量排版

目录

导读：先知道这份文档要回答什么 **3**
阅读路线 . . . 3
本版的证据边界 . . . 3

专题一：从原子坐标到能量和力 **4**
1.1 一个神经网络势到底接收什么 . . . 4
1.2 为什么力通常从能量求导 . . . 4
1.3 邻居图、截断与感受范围 . . . 4
1.4 训练与推理，不是同一项工作 . . . 4

专题二：MACE 用什么语言表示三维几何 **6**
2.1 不变性与等变性：转动体系后，什么应该变化 . . . 6
2.2 l、m、channel 和 parity 分别是什么 . . . 6
2.3 张量积：把两种方向信息组合成新的特征 . . . 6
2.4 多体阶数、消息层数与代际：三条不同的轴 . . . 7
2.5 “线性 MACE”为什么容易误导 . . . 7

专题三：PolarMACE 为什么需要全局电荷信息 **8**
3.1 极化、电荷转移与电荷态，不是一件事 . . . 8
3.2 用原论文图看完整计算流程 . . . 9
3.3 总能量的三部分，以及“密度”到底是什么 . . . 9
3.4 全局静电势如何进入原子网络 . . . 10
3.5 Fukui 平衡：按学习到的权重补足总电荷 . . . 10
3.6 两次更新不等于“迭代到收敛” . . . 11
3.7 Ewald：在周期空间计算长程库仑作用 . . . 11

专题四：Symmetrix-XL 怎样在不改模型时减少开销 **12**
4.1 先区分物理模型、计算图和执行计划 . . . 12
4.2 原论文的三条路线 . . . 13
4.3 为什么边数组比节点数组大 . . . 13
4.4 用代数重排理解“权重不变也能加速” . . . 14
4.5 当前 Symmetrix-Polar 真正实现到了哪里 . . . 14
4.6 原论文的速度与容量图，应该怎么读 . . . 15

专题五：读懂 GPU 优化必须知道的概念 **16**
5.1 CPU、GPU、kernel、thread、warp、block . . . 16
5.2 合并访存：让相邻线程读写相邻位置 . . . 16
5.3 计算受限、带宽受限和延迟受限 . . . 16
5.4 occupancy、并发覆盖与 GPU busy 不能混用 . . . 17
5.5 融合、预计算、复用和重算 . . . 17
5.6 Amdahl：一个算子快了，整个模型能快多少 . . . 17

专题六：我们的改动究竟优化了什么 **18**
6.1 先固定模型与测速边界 . . . 18
6.2 优化一：让 FP64 张量积也采用协作执行 . . . 18
6.3 优化二：重排消息汇总和边特征的线程 . . . 18

6.4 优化三：张量积里的共同项先算一次 18
6.5 优化四：边更新与拷贝融合 19
6.6 慢轮保留：为什么 224.1 与 224.4 都出现 19
6.7 历史上总体做到了什么 20
6.8 没成功的尝试，也能告诉我们什么 21

专题七：怎样证明算得对，而不是只跑得快 **22**
7.1 先问：是和谁比较，比较什么 22
7.2 能量误差、力误差和有限差分 22
7.3 为什么单点通过，第二次调用却可能错 22
7.4 已有 gate 证明了什么，没证明什么 22
7.5 测试矩阵应该怎样补齐 23

专题八：结果怎样比较，下一步怎样安排 **24**
8.1 两条测试分支分别汇报 24
8.2 4.50 µs/atom/step 是参照，不是 PolarMACE 的既定目标 24
8.3 RuNNer 2.0 与本项目，解决的问题有何不同 25
8.4 当前时间花在哪里 26
8.5 按优先级安排下一轮 26

附录 A：公式串起来看一遍 **27**

附录 B：符号与术语速查 **28**
B.1 数学符号 28
B.2 常见英文名称 28

附录 C：开会时可以直接使用的问答 **29**

附录 D：本版改正了旧报告哪些问题 **30**

附录 E：文献、图源与复算入口 **31**
E.1 原始文献 31
E.2 仓库证据索引 31
E.3 复算应做什么 31

导读：先知道这份文档要回答什么

本教程面向需要阅读、讲解和继续开发 Symmetrix-Polar 的读者。默认读者知道原子、能量和分子动力学的基本含义，但不要求预先掌握等变神经网络、Ewald 求和或 GPU 编程。正文沿着一条线展开：**原子坐标怎样变成能量和力，PolarMACE 为什么加入全局电荷信息，GPU 为什么会慢，我们的改动到底省掉了哪些工作。**

MACE、PolarMACE、Symmetrix-XL 和 Symmetrix-Polar 不是四个可以互换的名字。MACE 是模型架构；MACE-POLAR-1 是加入极化和长程静电的模型；Symmetrix-XL 是执行已经训练好的 MACE 模型的推理引擎；本仓库 Symmetrix-Polar 是对相应 C++/Kokkos 引擎的扩展和优化工作。模型规定“计算什么”，引擎决定“按什么顺序、在哪块内存、由哪些线程计算”。[P1，§2–5；P2，§II]

阅读路线

专题	要回答的问题	读完应能说明
一：从原子到能量	神经网络势输入、输出是什么?	能量、力、邻居图、训练与推理
二：MACE的几何语言	等变、通道、角动量、多体分别指什么?	不把阶数、层数、维数与代数混为一谈
三：PolarMACE 的全局响应	电荷密度、极化、Fukui、Ewald 如何连接?	为什么两个更新层不等于 SCF 收敛
四：Symmetrix-XL 的执行方法	streaming、specialization、tiling 为什么省内存?	公式不变时仍可改执行顺序
五：GPU 基础	有 GPU 为什么仍可能慢?	线程、warp、合并访存、算子启动与复用
六：本项目的优化	每项改动究竟改了什么?	用数据解释收益，并识别不成立的比较
七：正确性	“与参考一致”证明到什么程度?	单点、重复评估、轨迹与物理精度各自的边界
八：结果与下一步	现在多快、还缺什么?	准确汇报现状，安排下一轮实验

性能统一采用 **μs/atom/step**，即一次完整能量与力评估的耗时除以原子数。数值越小，单位原子的计算开销越低。这个归一化量仍受原子数、邻居密度、模型、精度和执行边界影响；不同体系的数值不能直接当成软件优劣排名。

本版的证据边界

本版重新读取了仓库中的 JSON、技术记录和两篇原论文，重算归一化数值、重画图表并修订解释，**没有重新运行 GPU benchmark**。因此文中的“实测”表示仓库已有历史测量，不表示本次编写时在新硬件上复测。模型与原实现的一致性也不能替代模型对 DFT 或实验的准确性验证。

最重要的两个结果分开记忆：

1. **128 原子 NH_3 分支**：Plan B-30ms 为 **238.7 μs/atom/step**，对应所记录 PyTorch 参考的 **734.4 μs/atom/step**，历史参考比值约 3.08。这一分支有明确的最终二进制与重复评估记录。[D1]
2. **1,296 原子 H_2O 分支**：最终候选的全部轮次中位数为 **224.4 μs/atom/step**；事后选出的两轮稳定轮中位数为 **224.1 μs/atom/step**。两种统计均保留。相对历史起点约少 51.6% 耗时，但不是同场端点 A/B，也不是独占 GPU 上的最终生产资格测试。[D2–D4]

汇报时可这样说：“我们在保留所测试 PolarMACE 计算结果的前提下，改写了 GPU 执行。128 原子分支相对已有 PyTorch 参考约快 3 倍；1,296 原子的历史工程链把耗时降低约一半。后者仍需独占 GPU 和最终版本的完整复验。”

专题一：从原子坐标到能量和力

1.1 一个神经网络势到底接收什么

考虑一个装有水分子的周期性盒子。每个原子有元素种类和三维坐标；盒子的三条边及周期性条件决定哪些周期镜像需要参与计算。普通局部势主要接收元素与几何；PolarMACE还需要体系电荷、自旋状态等电子状态信息。原子坐标相同，并不意味着不同电子数的体系能量相同。

输入	处理	输出
元素、坐标、晶胞、边界条件	建立邻居图，计算几何特征与网络特征	总势能
总电荷、自旋等模型支持的信息	选择电子状态并约束密度	状态相关的能量与响应
总势能对坐标、晶胞的导数	按完整计算链求导	力以及相应的应力

记模型参数为θ，原子坐标集合为$\mathbf{R}$，元素集合为$\mathbf{Z}$，总电荷为Q，电子自旋状态记号为S。模型可抽象写成

$$E_\theta = E_\theta(\mathbf{R}, \mathbf{Z}, Q, S).$$

这里的θ 是训练后固定的权重；$\mathbf{R}$ 在 MD 中逐步变化。Q, S 是否变化、怎样传入，取决于具体模拟协议和接口定义。不能把“模型接受电荷输入”理解成“引擎自动完成恒电势模拟”。

1.2 为什么力通常从能量求导

力决定原子下一刻向哪里运动。对原子i，能量型势的力为

$$\mathbf{F}_i = -\nabla_{\mathbf{R}_i} E_\theta.$$

负号表示原子受到朝向势能降低方向的力。若一维示例为$E(x) = kx^2/2$，则$F(x) = -kx$。这只是解释导数的弹簧算例，不是 PolarMACE 的实际势能表达式。

对一个复杂模型，坐标先影响邻居距离，再影响网络特征、极化密度和能量。求力必须对这些依赖一起使用链式法则。只对最后的库仑公式求导、却把由坐标决定的密度当作常量，通常会漏掉力的贡献。MD 还需要速度、质量、时间积分和温控等步骤；模型的一次评估不是全部模拟流程。

1.3 邻居图、截断与感受范围

把原子画成节点，把截断距离内的相互作用记录为有向边，就得到邻居图。边$j \to i$ 表示原子j 向原子i 提供信息；它是计算关系，不等于化学键。两原子即使没有形成共价键，也可能在邻居图里相连。

若$r_{ij} < r_c$，通常将j 加入i 的邻居表。实现还可能保留一层 skin：先建稍大的表，在原子移动较小时复用，避免每步重建。**模型截断r_c 与邻居表半径r_c + skin 不同**；skin 内的额外边不应改变定义好的势能。

一层消息传递只读一跳邻居；多层可沿图传播更远。Tr_c 可以作为有限层传播范围的粗略上界，但不代表所有这个半径内的几何都以同样方式参与。层数有限时，信息范围仍有限；显式全局静电则提供另一条信息通道。[P1，§2；P2，§II]

1.4 训练与推理，不是同一项工作

训练用 DFT 等参考数据调整θ；推理在固定θ 后，对新的结构算能量和力。本项目主要优化推理执行，不是训练一个新的基础模型，也不是把 PolarMACE 蒸馏成小模型。

有三种不同的准确性问题：训练模型能否预测参考物理；模型能否泛化到目标体系；本引擎是否忠实执行该模型。本仓库的许多数值门主要回答第三项。即使引擎与 PyTorch 差到机器舍入量级，也不能据此宣称目标反应势垒已经达到 DFT 精度。

本专题检查点。能解释一个水盒子怎样产生能量和力；知道邻居边不是化学键；知道“保持权重不变的加速”与“重新训练更小模型”是不同路线。

专题二：MACE 用什么语言表示三维几何

2.1 不变性与等变性：转动体系后，什么应该变化

把整个结构刚性转动，内部距离与夹角不变，总势能应该不变；力是空间向量，应跟着转动。对旋转矩阵$\mathbf{R}_{\text{rot}}$，

$$E(\mathbf{R}_{\text{rot}}\mathbf{R}) = E(\mathbf{R}), \qquad \mathbf{F}_i(\mathbf{R}_{\text{rot}}\mathbf{R}) = \mathbf{R}_{\text{rot}}\mathbf{F}_i(\mathbf{R}).$$

第一条叫旋转不变，第二条叫旋转等变。**等变不是“不允许变化”，而是“按规定的方式变化”。**例如绕z 轴转90°，向量$(1,0,0)$ 应变成$(0,1,0)$，向量长度仍为 1。MACE 在内部也使用遵守这些变换规律的特征。[P1，§2；P3]

相同元素原子的编号互换不应改变总能量；整体平移也不应改变孤立体系的内部能量。这些对称性帮助网络把学习能力用于实际化学差别，而不是重复学习坐标系的任意选择。

2.2 l、m、channel 和 parity 分别是什么

可以把等变特征理解成“按旋转规律分好类的多组数”。旋转角动量阶数l 对应每组的$2l+1$ 个几何分量；m 标识这组内部的分量；channel 表示同一种变换类型有多少组可学习特征。

$$\mathbf{h}_i^{(l,p)} \in \mathbb{R}^{C_{l,p}\times(2l+1)}.$$

这里i 是原子，$C_{l,p}$ 是通道数，p 是空间反演的奇偶性。对完整$O(3)$ 表示，需要同时指定l 和p。$l=1$ 本身只说明旋转类型；通常的极向量是 1o，轴向量可以是 1e，不能把所有$l=1$ 一律叫 1o。

例子	单组分量数	直观理解
0e	1	旋转与反演下不变的标量
1o	3	像位移或力那样变换的极向量
2e	5	对称无迹二阶张量的独立分量
3o	7	更高阶的方向信息

算例。“512x0e + 512x1o”共有$512\times 1+512\times 3=2048$ 个标量存储位置。如果另一处张量为“512x0e + 512x1o + 512x2e + 512x3o”，其大小是$512(1+3+5+7)=8192$。这两个张量出现在不同运算阶段，不能据此把整个模型的每一层都写成 8192 维。

这里没有增加新的空间维度。原子仍在三维空间中；8192 是某个特征数组的宽度。它也不是“第几代神经网络”的代数。

2.3 张量积：把两种方向信息组合成新的特征

两个等变对象相乘后，需要把结果重新分解到允许的旋转类型。Clebsch–Gordan系数给出这种组合的固定几何规则。一个便于阅读的示意式是

$$y_{c,lm} = \sum_{\pi,m_1,m_2} w_{\pi c}\, C^{lm}_{l_1m_1,l_2m_2}\, x_{c,l_1m_1}\, z_{l_2m_2}.$$

C 是固定耦合系数；w 是具体模型中的学习权重或由网络生成的权重；π 区分允许的耦合路径。允许的旋转阶数满足$|l_1-l_2|\le l\le l_1+l_2$，反演奇偶性需满足相应的乘积规则。

点积与叉积是熟悉的低阶例子：两个向量的点积给出标量，叉积给出轴向量。实际 MACE 的通道混合、路径权重和乘积基更丰富，不能把全部张量积缩成一次普通矩阵乘法。[P1，§2–4；P3]

为什么这会成为热点？对很多原子、边和通道反复执行稀疏耦合时，固定的小系数表会被重复读取，相同局部收缩可能重复计算。优化可以利用这些固定规律，但不能删掉训练模型要求的耦合路径。

2.4 多体阶数、消息层数与代际：三条不同的轴

多体阶数描述原子环境中同时耦合了多少个粒子的几何信息。例如单个原子对的距离是二体信息，中心原子与两个邻居形成的角度是三体信息。MACE利用乘积基高效构造更高体阶消息，不需要显式枚举每一种邻居元组。[P3]

消息层数描述信息经过多少轮图更新；$l_{\max}$ 描述保留到多高阶的方向表示；2G/3G/4G 则是另一种按局域性、长程作用和全局电子响应划分势模型的方法。

名称	真正在问什么	不能据此推断
$l_{\max}$	方向表示保留到几阶？	模型属于第几代
channel 数	同类型特征有多少组？	电子数或空间维数
body order	同时耦合多少粒子的几何？	信息一定传得更远
interaction 层数	信息经过多少轮图更新？	自动具备无限程响应
代际分类	是否处理全局电子状态与非局域响应？	精度或速度必然更高

标准局部 MACE 可对应广义 2G 范畴；PolarMACE 具有全局电子响应，按能力可讨论为广义 4G。这个对应不是两篇论文给出的统一官方型号，也不意味着 PolarMACE 使用 RuNNer 的 QEq 实现。

2.5 “线性 MACE”为什么容易误导

旧报告用“线性路径”和“非线性 PolarMACE 路径”对照执行分支，这种工程简称不能直接变成物理定义。标准 MACE 同样有非线性和高体阶乘积；普通 MACE 的径向网络也可以给不同边生成不同权重。**不能说普通 MACE 的所有权重都固定、每条边都完全独立。**

本教程采用明确名称：“MACE-OFF23 的标准 streamed/direct 路径”与“本仓库当前支持的 MACE_Nonlinear/PolarMACE materialized 路径”。实际是否能融合、预计算或重排，要看具体算子的依赖，不只看最后 readout 是线性层还是 MLP。

专题三：PolarMACE 为什么需要全局电荷信息

3.1 极化、电荷转移与电荷态，不是一件事

极化是电荷分布在电场作用下重排。例如中性片段内一侧电子稍多、另一侧稍少，整体仍然中性。**片段间电荷转移**是按某种分区定义，两个片段的净电荷发生交换。**改变总电荷态**则是整个体系电子数改变，需要明确电子库或所研究的电荷态。

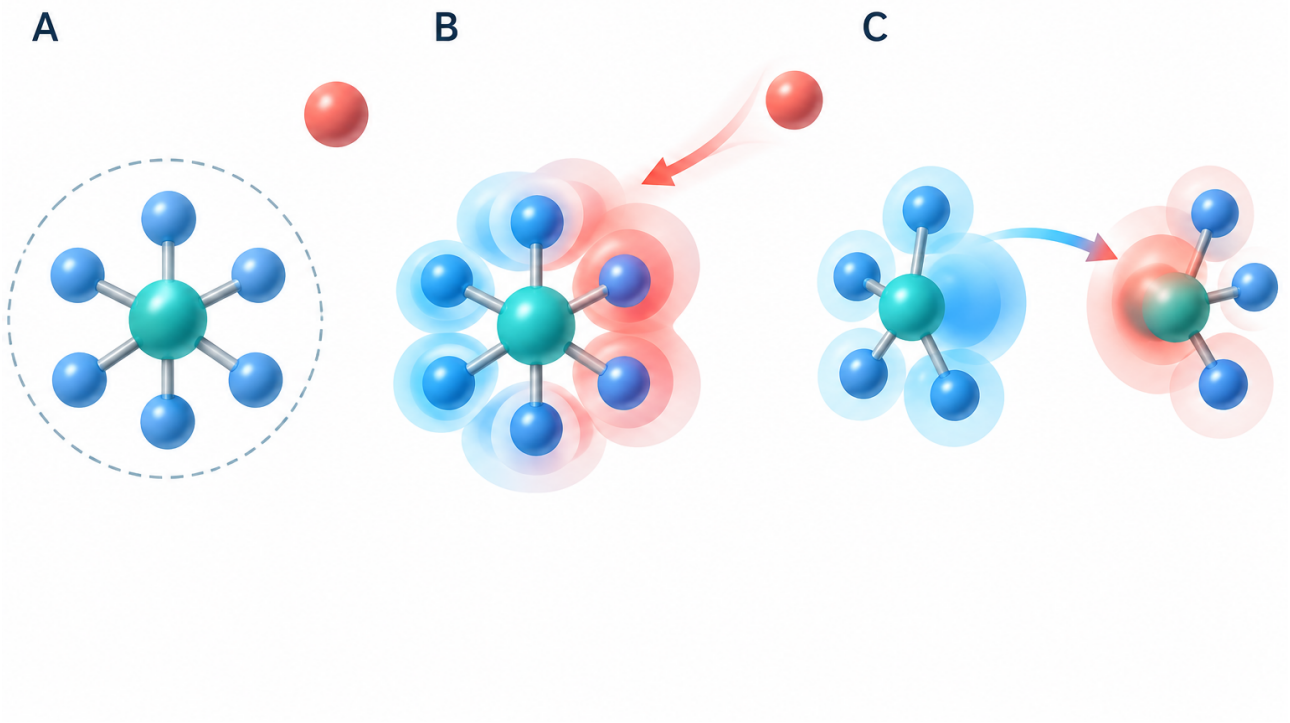


图 3-1 ｜局部环境、极化和片段间电荷转移的概念示意。A 的虚线表示有限局部范围；B 的半透明区域只表示定性重排；C 表示片段净电荷变化的概念。球体不指定真实元素，云图不是计算密度，颜色不承担定量或正负电荷标定。AI 生成，仅用于讲解。

有限范围的几何网络可能无法区分“局部几何相同、远处环境不同”的两个结构。PolarMACE 先用局部 MACE 提取几何，再通过全局静电信息更新密度，使远处的影响能回到局部能量预测中。[P2，§II.B]

3.2 用原论文图看完整计算流程

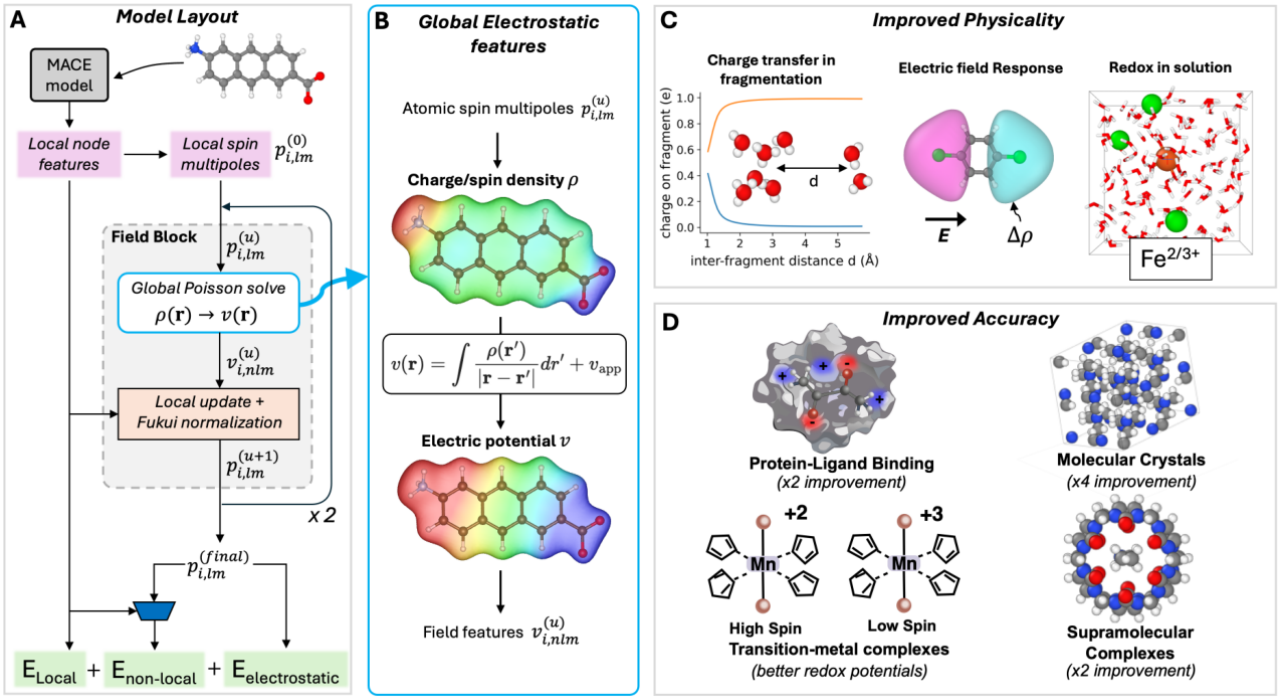


图 3-2 | MACE-POLAR-1 原论文图 1，完整图的裁切提取，未改写图中数据。来源：Batatia 等，arXiv:2602.19411v1，PDF 第 4 页。原图 C、D 是原论文的模型能力与基准展示，不是本仓库重新验证的结果。

先看原图 A：原子结构进入局部 MACE，产生局部特征和初始 spin-charge multipoles；进入 Field Block 后，根据全局密度算静电势，再局部更新多极矩并进行 Fukui 归一化。这个块执行两次，最后计算能量。

再看 B：密度产生静电势，静电势投影回原子中心特征。重点是**从全体系出发、回到各原子**的信息通道，不是要求把每个原子的所有远邻都塞进原来的局部邻居表。

最后看 C、D：原论文用片段解离、外电场、氧化还原和非共价相互作用等任务说明模型作用。不能把这张图当成 Symmetrix-Polar 的新增 benchmark，也不能把原论文的所有应用精度自动转移到当前引擎版本。

3.3 总能量的三部分，以及“密度”到底是什么

遵循原论文式（1），

$$E_{\text{total}} = E_{\text{local}} + E_{\text{nonlocal}} + E_{\text{electrostatic}}.$$

局部项学习近程化学环境的主要能量；静电项描述平滑电荷密度的长程库仑能；非局域学习项利用局部几何和全局电荷／场特征，补充单纯库仑项之外的能量贡献。[P2，§II.A、II.B.5–6]

这个分解不是可以任意相加的三个独立模型；它们是在同一学习框架中定义、协同拟合的。原文说明非局域学习项可承载包括色散在内的残余效应，**不能据此宣称它自动满足任意远距离的准确C_6/r^6 渐近式，或等于单独添加 D3/D4**。

原论文采用的是粗粒化残余电荷密度，形式上对应核正电荷与电子负电荷抵消后的平滑剩余。它不是 DFT 中带核尖峰和芯电子细节的完整电子密度，也不是对 Bader 电荷的唯一重建。

对自旋通道$\sigma \in \{\uparrow, \downarrow\}$，

$$\rho^{\sigma}(\mathbf{r}) = \sum_{i,l,m} p^{\sigma}_{i,lm}\, \phi_{lm}(\mathbf{r} - \mathbf{R}_i).$$

p 为原子中心多极系数，ϕ 为带球谐角向结构的 Gaussian 基函数。单极刻画净电荷，偶极刻画方向性分布；更高l表示更细的方向结构。原论文中的自旋通道残余电荷是建模变量，不要把两通道都当成非负电子概率密度。[P2，式（2）–（10）]

3.4 全局静电势如何进入原子网络

无外场时，教学形式的库仑势为

$$v^{\sigma}(\mathbf{r}) = \int \frac{\rho^{\sigma}(\mathbf{r}')}{|\mathbf{r} - \mathbf{r}'|}\, d\mathbf{r}'.$$

远处密度也出现在积分里，因此它具有全局依赖。把v^{σ} 投影到原子中心基函数，得到网络能够使用的特征，

$$v^{\sigma}_{i,nlm} = \frac{1}{\mathcal{N}_{nl}} \int \phi_{nlm}(\mathbf{r} - \mathbf{R}_i) v^{\sigma}(\mathbf{r})\, d\mathbf{r}.$$

n 标识径向基，l, m 标识角向分量，$\mathcal{N}_{nl}$ 是规定的归一化。投影可以理解为：用一组固定“探针”测量原子附近电势的不同方向和尺度。本教程这两式省略外加电势；原论文对每个自旋残余电荷通道使用$v_{\text{app}}/2$。[P2，式（16）–（17）]

3.5 Fukui 平衡：按学习到的权重补足总电荷

网络初步给出的单极$\tilde{q}_i$ 未必恰好满足总电荷约束。Fukui 机制为每个原子学习一个响应权重，并把总量差额分配回去。忽略自旋分解的教学形式为

$$w_i = \frac{f_i}{\sum_j f_j}, \qquad q_i = \tilde{q}_i + w_i \left(Q - \sum_j \tilde{q}_j \right).$$

只要分母定义良好，就有$\sum_i w_i = 1$，因此$\sum_i q_i = Q$。这里f_i 的具体生成和数值稳定处理属于模型定义，不能由引擎随意替换。

三原子算例。设初值为$(0.10, -0.20, 0.00)$，总目标$Q = 0$，归一化权重为$(0.50, 0.30, 0.20)$。初值之和为-0.10，还需补$+0.10$，因此修正为$(+0.05, +0.03, +0.02)$，最终得到$(0.15, -0.17, 0.02)$，和为 0。这个算例只展示归一化代数，没有指定真实分子的电荷。

实际模型有两个自旋通道，按原论文约定分别满足

$$Q^{\uparrow} = \frac{Q + S}{2}, \qquad Q^{\downarrow} = \frac{Q - S}{2}.$$

原论文此处S 是两残余电荷通道的归一化差，采用$N_{\text{el}}^{\downarrow} - N_{\text{el}}^{\uparrow}$ 的约定。程序中的字段 spin 可能是多重度M 而不是这个S；本仓库补丁记录了使用$M - 1$ 的转换。**比较接口前必须核对语义，不能把论文S、物理自旋量子数和输入多重度直接互换。**闭壳层通常用$M = 1$，相应通道差为 0。[P2，式（10）、（13）–（15）、（26）–（27）；仓库 polar 支持补丁]

Fukui 归一化提供总量约束，但只加这个约束并不保证模型已经正确描述任意长程电荷转移。PolarMACE 的全局响应还依靠前述电势特征更新；物理效果最终需要具体测试。

3.6 两次更新不等于“迭代到收敛”

用简写表示一个更新层：

$$\tilde{\mathbf{p}}^{(u+1)} = \mathbf{p}^{(u)} + \Delta_{\theta}^{(u)}(\mathbf{h}, \mathbf{p}^{(u)}, \mathbf{v}^{(u)}), \qquad \mathbf{p}^{(u+1)} = \mathcal{F}_{Q}^{(u)}(\tilde{\mathbf{p}}^{(u+1)}).$$

h 是局部几何特征，**p** 是多极系数，**v** 是由全局密度得到的场特征；$\mathcal{F}_{Q}$ 表示带电荷／自旋目标的 Fukui 修正。上标u 表明不同更新层可以有各自的学习参数。

MACE-POLAR-1 的原文是 **non-self-consistent field formalism**，当前模型执行两次学习型全局更新。它受 SCF 思想启发，但没有要求重复同一映射直到$\|\mathbf{p}^{(u+1)} - \mathbf{p}^{(u)}\|$ 小于收敛阈值。[P2，§II.B.4、II.B.7]

因此仓库旧文中的 “SCF” 在本教程统一解释为历史代码名称。把两次更新改成一次，会改变训练模型定义，不是单纯调低一个求解器精度；把两次改成很多次也不能自动获得更精确答案。

3.7 Ewald：在周期空间计算长程库仑作用

周期性盒子代表无限重复的结构。直接把所有周期镜像两两相加既慢又需要谨慎定义求和与边界条件。周期静电可以在倒空间组织：先求各波矢的密度系数，再用库仑核组合能量。

为避免不同 Fourier 约定混淆，本教程明确定义

$$\rho_{\mathbf{k}} = \int_{\Omega} \rho(\mathbf{r}) e^{-i\mathbf{k}\cdot\mathbf{r}}\, d\mathbf{r}, \qquad \rho(\mathbf{r}) = \frac{1}{\Omega} \sum_{\mathbf{k}} \rho_{\mathbf{k}} e^{i\mathbf{k}\cdot\mathbf{r}}.$$

在原子单位、三维周期、净电荷为零、无外场的前提下，

$$E_{\mathrm{H}} = \frac{1}{2\Omega} \sum_{\mathbf{k}\neq 0} \frac{4\pi}{|\mathbf{k}|^2} |\rho_{\mathbf{k}}|^2.$$

Ω 是晶胞体积，**k** 为倒格矢。这与原论文采用另一 Fourier 归一化的式（40）–（42）等价；**前面的系数必须与密度变换定义成对使用**。

Gaussian 密度基的 Fourier 变换本身已经带有衰减。若把它包含在$\rho_{\mathbf{k}}$ 中，不能再无依据地乘一次传统 Ewald screening 因子；否则可能重复衰减、改变模型。有限倒空间截断仍有数值误差，仓库 “exact/full-k” 表示求完所选截断内的格点，区别于随机抽样，不等于数学上无限求和绝对无误差。[P2，§II.B.6、SI V.F]

非中性周期体系需要说明背景、边界和有限尺寸修正；删掉$\mathbf{k} = 0$ 并不能自动解决所有带电缺陷能问题。本项目的特定测试通过不代表所有边界条件均已验证。

本专题检查点。能沿 “局部特征 → 初始多极 → 全局电势 → 局部更新 →Fukui 修正 → 重复两层 → 三部分能量” 讲清流程；知道学习到的残余密度、SCF 收敛、QEq 和 Bader 电荷不能混称。

专题四：Symmetrix-XL 怎样在不改模型时减少开销

4.1 先区分物理模型、计算图和执行计划

给定训练权重和结构，模型规定一组数学运算；计算图表达运算之间的依赖；执行计划决定中间量保存多久、怎样分块、什么时候重算、由哪些线程负责。

例如$q_i = \sum_{j \in \mathcal{N}(i)} u_{ji}$。可以先算完全部边的$u_{ji}$，保存大数组，再对每个原子求和；也可以每算出一条边的贡献就累加给q_i。数学目标相同，中间存储不同。浮点加法不严格满足结合律，所以改变累加顺序后仍需数值核验，不能简单宣称逐位相同。

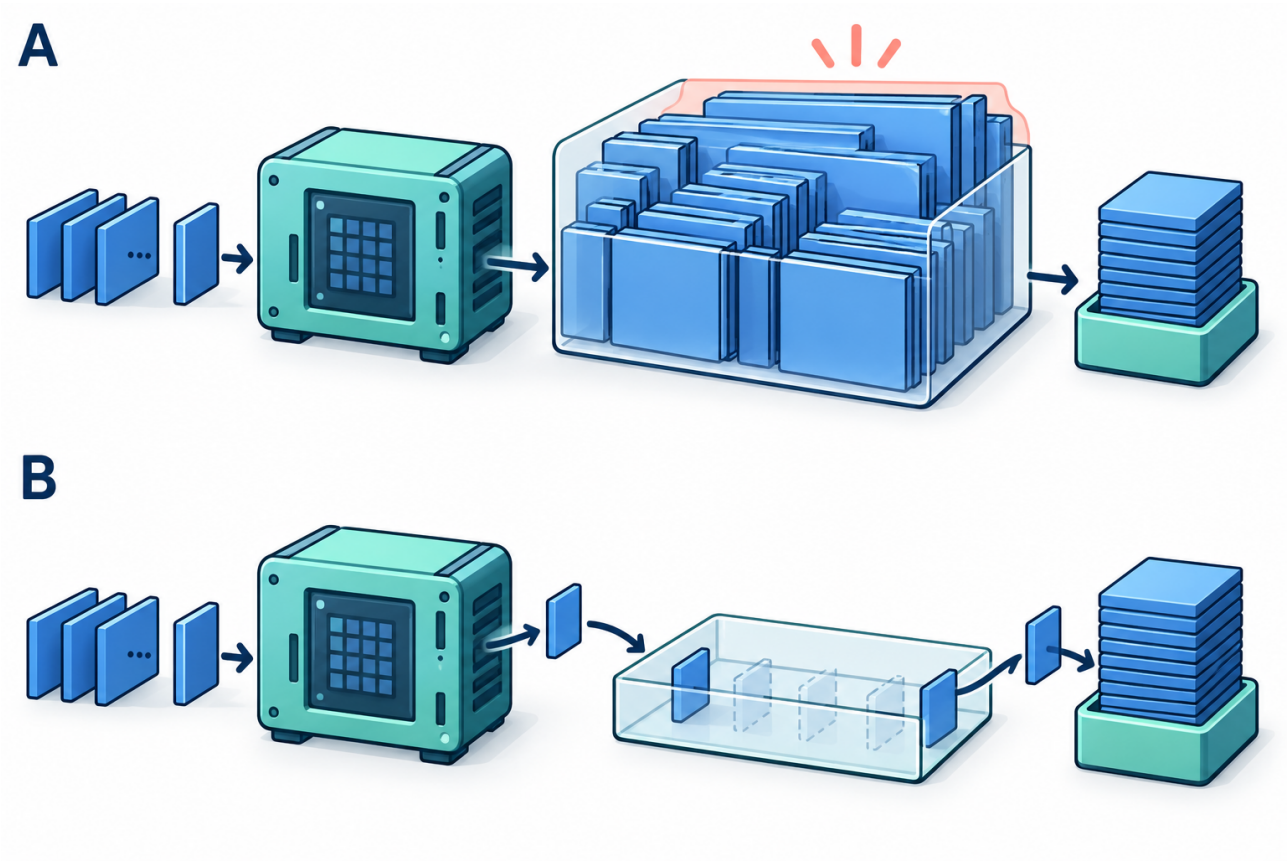


图 4-1 | “全部保存再汇总”与“边算边汇总”的概念比喻。A 中大量宽中间量占用存储；B 中每份中间量用完便释放，只保留必要的最终汇总和跨层状态。图示不是性能测量，也不表示所有输入或反向依赖都可以丢掉。AI 生成，仅用于讲解。

这个例子说明的是调度自由度，不是允许删除全局物理。PolarMACE 仍然需要全局密度和场；全局状态存在，并不在逻辑上禁止把某些局部边运算流式化。

4.2 原论文的三条路线

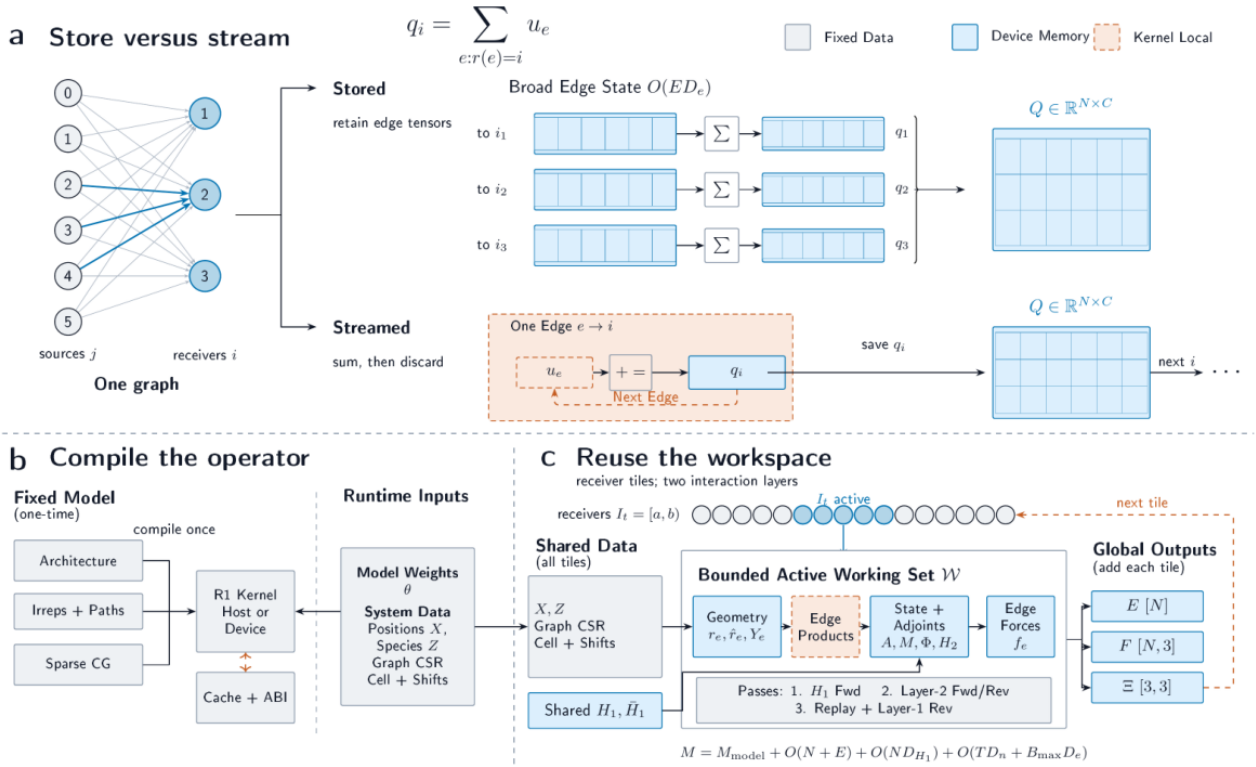


图 4-2 | Symmetrix-XL 原论文图 1，原图裁切提取。来源：Fu 等，arXiv:2610.01036v1，PDF 第 2 页。A 解释 store 与 stream；B 解释固定架构的代码生成；C 解释工作区分块复用。它说明的是 Symmetrix-XL 原论文实现，并不意味着本仓库 PolarMACE 分支已实现全部路径。

第一条，streamed-edge execution。展开的边权重和张量积贡献在接近使用位置时生成，累加到接收原子后释放，避免全图同时保存大量宽边数组。仍需保留图、几何和必要节点状态。

第二条，model-specialized execution。固定模型的允许耦合路径、通道数和数组布局在模拟前已知，可以生成专用代码，减少每次推理对通用稀疏计划的解释。原子数和邻居图仍可改变；“专用代码”不等于只能算某一个固定盒子。

第三条，tiled execution。将接收原子及关联边分成有限大小的 tile，复用一块工作区。必要的跨层节点状态仍可保留在全图；边上的较大临时数组限制在当前 tile 内。它以部分重算和调度开销换取更大容量。[P1，§3–5]

4.3 为什么边数组比节点数组大

记原子数为N，平均有向邻居数为z，边数为$N_e \approx Nz$。如果每条边保存宽度W_e 的数组，每个数占b 字节，

$$M_{\text{edge}} \approx N_e W_e b.$$

教学算例。取$N_e = 100000$、$W_e = 8192$、FP64 的$b = 8$，单个边数组约占6.10 GiB。若还有输入、输出、反向中间量和其他层，峰值内存会继续增加。这不是本模型实测峰值，而是帮助理解宽边数组的量级。

同样宽度的节点数组只随N 增长。平均每个原子几十到上百条有向边时，把可消去的宽边量留到全图，会比保留相应节点量昂贵得多。高密度、较大截断半径与更多通道通常都会增加开销，但不同项的比例需实测。

streaming 主要减少展开数组的存活期。不能把内存复杂度写成“全程$O(1)$”：邻居图和节点特征依旧随体系增大。[P1，§3]

4.4 用代数重排理解“权重不变也能加速”

原论文给出紧凑径向嵌入φ_{eq}到展开边权重的投影，

$$W_{e,\pi a} = \sum_q \varphi_{eq} B_{q,\pi a}, \qquad \mathbf{m}_i = \sum_{e:r(e)=i} \sum_{\pi,a} W_{e,\pi a}\, T_{\pi a}(\mathbf{h}_{s(e)}, Y_e).$$

符号含义：$s(e)$是边的源原子，$r(e)$是接收原子，q是紧凑径向分量，π, a表示路径及其分量，B是训练权重，T是相应角向／源特征收缩。

把第一式代入第二式后，展开权重可以即时产生，不必为所有边同时存储。反向传播也能使用同一重排的转置，并按需重算局部因子。这是代数与内存调度协作，不是降低网络表达能力。[P1，§3]

某些模型会让边更新依赖两端节点特征，或在场更新中引入更复杂依赖；此时能否复用相同重排要重新分析。但“有MLP”“有动态边权”都不是不能 streaming 的充分理由。

4.5 当前 Symmetrix-Polar 真正实现到了哪里

本仓库记录：MACE-OFF23可以使用 direct/JIT streamed 路径；当前 PolarMACE 的相应 pair style 仅接通 materialized 执行，直接拒绝不支持的 direct/JIT 请求。因此，它尚未把原论文所有容量优势带到 full PolarMACE。[D5]

必须分清三个说法：

1. “当前实现没有接通”是软件事实，可以通过代码和运行记录检查。
2. “这个公式需要保留全局节点／密度状态”是数据依赖事实。
3. “任何实现都不可能对该模型 streaming”是很强的理论结论，现有材料不支持。

后续可研究局部边算子的分块、必要状态与可重算状态的拆分，以及极化更新边界上的全局同步。是否值得做，取决于容量、额外重算和通信的实测权衡。

4.6 原论文的速度与容量图，应该怎么读

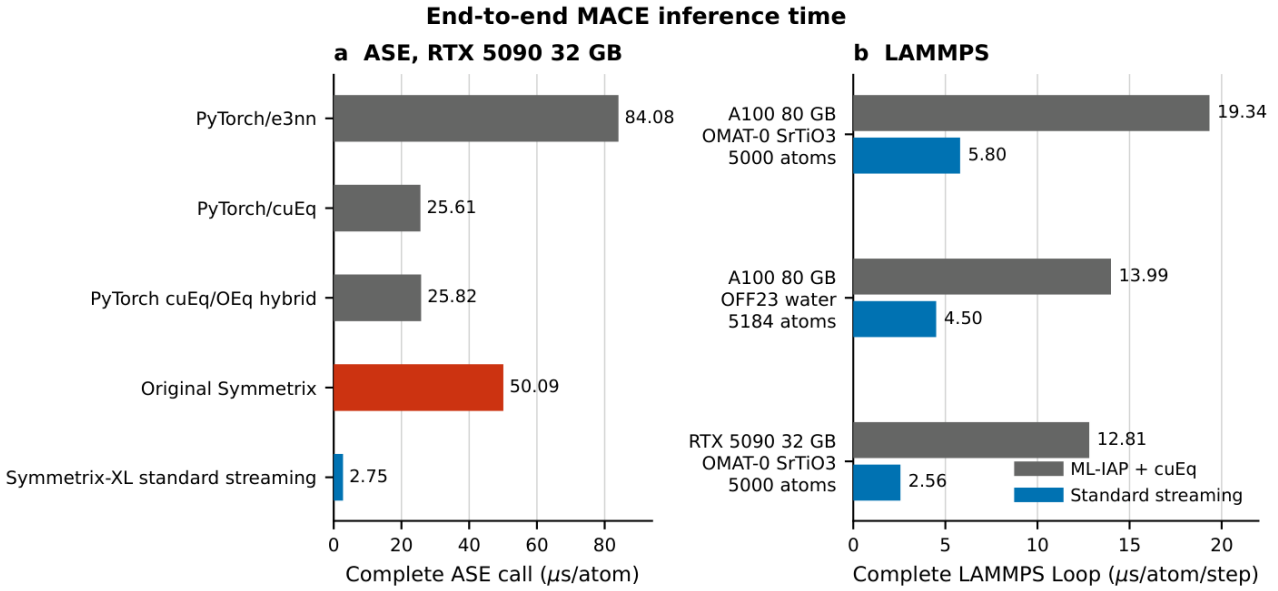


图 4-3 | Symmetrix-XL 原论文图 2 的图形部分。来源：arXiv:2610.01036v1，PDF 第 6 页。A 是完整 ASE 能量／力／应力调用；B 是 FP32 LAMMPS Loop。两个面板的执行边界不同，不能直接互除。

原论文的 A100、OFF23 水体系点为 **13.99 → 4.50 μs/atom/step**，是在同一 5,184 原子体系、FP32、相应静态计时协议下比较 ML-IAP + cuEquivariance 与 standard streaming。它不是 PolarMACE 的测量；也不是本项目相对自己早期 C++ 引擎的加速倍数。[P1，§6、图 2]

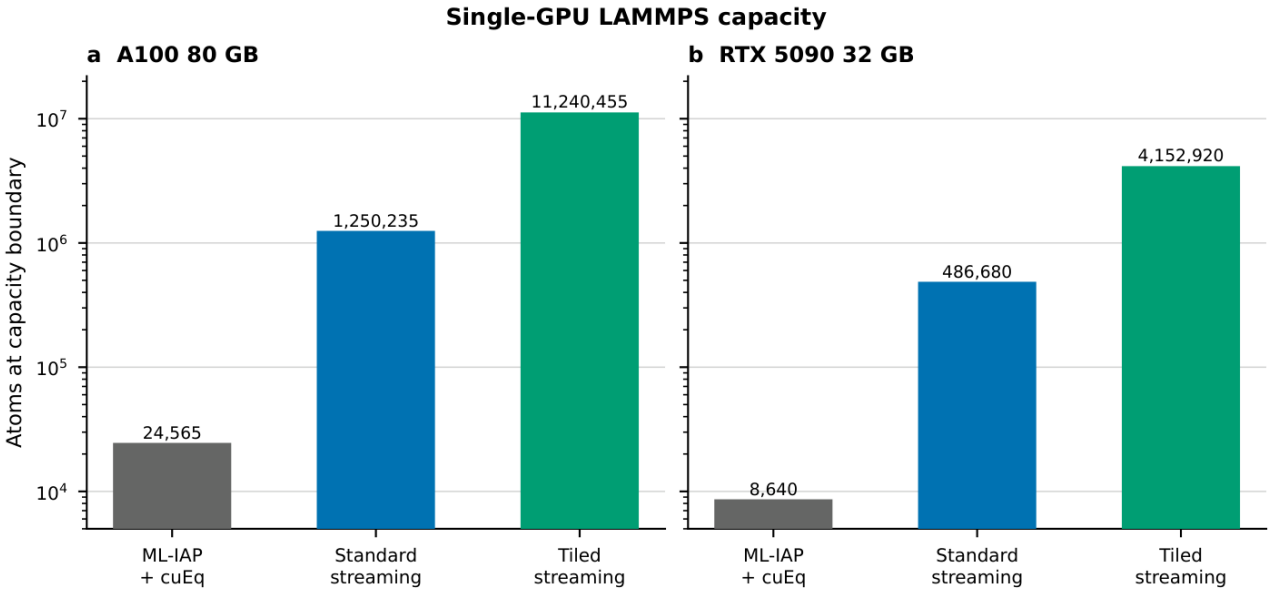


图 4-4 | Symmetrix-XL 原论文图 3 的容量图。来源：arXiv:2610.01036v1，PDF 第 7 页。容量是各配置下可完成规定探测的最大体系，不是同尺寸速度比较；原文注明这些边界探测不能当作持续 20 步 MD。

百万原子容量展示属于指定的 MACE-OMAT-0、FP32 和执行计划。不能据此说本仓库 full PolarMACE 已能算千万原子。容量、吞吐量和长时间稳定性是三项不同指标。

专题五：读懂 GPU 优化必须知道的概念

5.1 CPU、GPU、kernel、thread、warp、block

CPU 适合灵活控制、串行逻辑和复杂流程；GPU 适合大量结构相似的工作。GPU 加速的前提是任务能形成足够并行度、数据移动合理，而且每次发起任务的开销没有压过实际计算。

概念	直白解释	在本项目里的例子
kernel	一次提交给 GPU 的并行程序	汇总邻居消息、计算张量积
thread	一个逻辑执行线程	计算某个原子的一项特征
warp	NVIDIA 中按组执行的 32 个线程	相邻线程最好访问相邻数据
block	一组可协作并共享局部内存的线程	共同计算一个节点或收缩任务
SM	执行许多线程块的硬件计算单元	任务太少时部分 SM 无工作
register	线程内很快但容量有限的存储	保存局部累加器
shared memory	block 内线程共享的局部存储	缓存耦合表和预收缩结果
device/global memory	容量大的 GPU 显存	存邻居图和全局数组

Kokkos 用跨平台抽象描述这些执行组织。TeamPolicy 可以让一组线程合作完成任务；MDRange 可以把多维索引分配给线程。它们不是换个名称就一定更快，实际效果取决于工作量、内存访问和资源占用。

5.2 合并访存：让相邻线程读写相邻位置

假设一个二维边特征数组按行存储，每行是一条边的全部特征。一条边一个线程时，warp在同一条存储指令中可能写 32 条相隔很远的行。改成按“边、特征”二维分工，相邻线程可写同一行的相邻分量，通常更容易合并访问。

旧报告把这一点说成“32 倍写放大”，不够严谨。以对齐的 FP64 store 为教学算例：32 个线程各写 8 字节，有效载荷为 256 字节；若每个线程都落在不同的 32 字节 sector，就涉及 32 个 sector；连续访问的理想情况涉及 8 个 sector。

$$A_{\text{sector}} = \frac{32 \times 32}{32 \times 8} = 4.$$

这是**单条理想化访存指令的 sector 比值**，不是已经测到的总 DRAM 流量放大。缓存命中、后续相邻写入、指令合并和实际地址对齐都会影响总流量；不能据这个算例推断整个模型必然快 4 倍。32 字节 sector 也不能简单称为物理 DRAM 总线的最小事务。

5.3 计算受限、带宽受限和延迟受限

算术强度I 表示每移动一个字节做多少次浮点运算。经典 roofline 的示意上界为

$$P \le \min(P_{\max}, I\, B_{\text{mem}}).$$

P 是性能，$P_{\max}$ 是相关指令类型的峰值性能，B_{mem} 是相关内存层级的带宽。这个模型有助于判断上界，但真正程序还可能受小任务、启动开销、同步、寄存器压力和稀疏索引影响。

“张量积运算多”不等于已经证明它计算受限；“gather 在搬数据”也不等于已经证明它跑满显存带宽。本项目有 CUPTI 时长和启动形状信息，但相关记录说明没有完整硬件计数器测量。因此本文将这些作为诊断假设，不把推测写成已证实瓶颈。

5.4 occupancy、并发覆盖与 GPU busy 不能混用

occupancy常指一个 SM 上活跃 warp 占理论最大值的比例；SM 覆盖涉及有多少 SM 能分到工作；GPU busy 时间表示 GPU 有 kernel 在执行。三者相关但不是同一个量。

例如一个很小的 kernel 可以只占少数 SM，却持续执行很久，使 “GPU busy” 看起来很高。反过来，提高每线程寄存器使用来增加局部复用，也可能降低 occupancy，却减少了访存而更快。

本仓库某些 occupancy/coverage 指标由 block 数、寄存器和共享内存需求估算，属于**静态估计**。它们不能冒充由硬件计数器测到的 achieved occupancy，也不能仅凭一个估计值断言 “GPU 只用了 40%”。

5.5 融合、预计算、复用和重算

融合是把本来分开的步骤放进同一个执行单元，例如生成中间量后直接汇总，少写一次显存、少启动一个 kernel。预计算是把输入不变的工作提前做一次；复用是让多个通道或调用共享已有结果；重算则用额外计算换更小的中间存储。

四者都有代价。融合可能增加寄存器和同步压力；预计算需要缓存，且输入变化时必须失效；复用必须符合数据依赖；重算可能增加总算术量。优化应比较完整模型耗时，而不是只挑某个 kernel 的最佳数字。

5.6 Amdahl：一个算子快了，整个模型能快多少

若某部分占原始全步耗时比例f，该部分加速s 倍，其余不变，则

$$\frac{T_{\text{new}}}{T_{\text{old}}} = (1-f) + \frac{f}{s}, \qquad S_{\text{whole}} = \frac{1}{(1-f) + f/s}.$$

全步耗时减少比例为$f(1-1/s)$。例如$f = 0.25$、$s = 2.22$，全步耗时减少约 13.7%，整体加速约 1.16 倍。旧报告将这组假设与 “减少 6.9%” 直接配对，分母不一致；6.9% 只能在另一占比或实际端到端测量下成立。

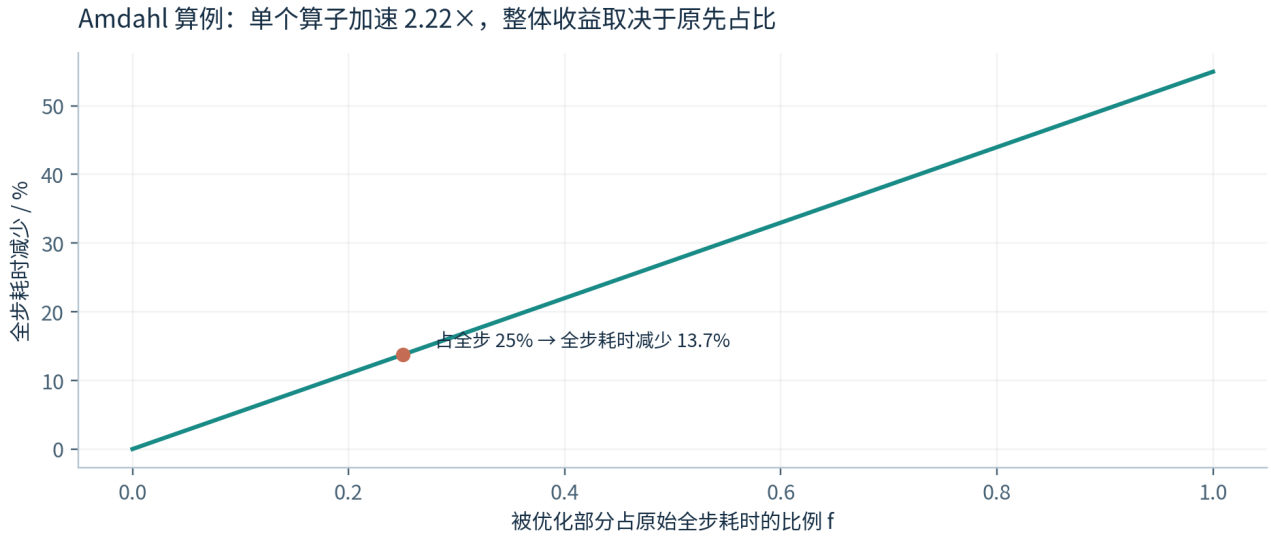


图 5-1 | Amdahl 教学算例，由 Python 按给出的公式计算，不是 benchmark。算子加速固定为 2.22 倍；曲线展示该算子占原始全步不同比例时，整体能减少多少耗时。

本专题检查点。能解释为什么合并访存通常有帮助、为什么 GPU busy 不能当成硬件利用率、为什么单算子加速不能直接当成完整模型加速。

专题六：我们的改动究竟优化了什么

6.1 先固定模型与测速边界

本专题主体为 **1,296 原子 H_2O、full PolarMACE、FP64、单张 A100 80GB**。历史记录主要用预热后多次短 run 的每步评估计时。它能观察稳态调用成本，但与原论文“5 次预热、20 次测量、3 个新进程”的完整 LAMMPS Loop 协议不同。[D2、D5]

这里的 step 是一次模型能量与力评估。若静态结构重复调用，邻居表通常可复用；真实 MD 中还会有邻居重建、积分、通信和输出等开销。**本文每个模型评估的性能不能直接承诺真实长轨迹的相同吞吐量。**

原始日志以整次调用时间记录，本教程按

$$u = \frac{10^6\, T_{\mathrm{eval}}}{N} \quad [\mu\mathrm{s/atom/step}]$$

统一转换，式中T_{eval} 以秒计，N 为实际参与体系的原子数。计时器需要正确同步 GPU，否则测到的可能主要是 CPU 提交任务时间。

6.2 优化一：让 FP64 张量积也采用协作执行

MH-1是仓库对一类张量积执行路径的工程名称，不是“第一代神经网络”。旧路径让 FP64 使用较通用的组织；team 路径让一组线程共享局部工作和耦合计划，以减少重复读取和串行循环。

历史记录显示这一步有明显收益，但最初打开 FP64 team 路径时暴露了重复调用状态错误。**错误修复前，即使某次单点通过，也不能把该版本列为已通过生产验收的加速结果。**本教程历史图不再把这些未修复 team 数字当作可靠的累计阶梯。[D4]

随后 B4 将反向中的 edge-to-node gather 融入相应张量积反向，避免先写边伴随量再单独汇总。伴随量可以理解为“后续输出对当前中间变量有多敏感”，是链式求导传回来的量。

6.3 优化二：重排消息汇总和边特征的线程

message gather对各邻居的消息求和。原先线程布局让相邻线程访问相距较远的位置；新的 tile 让特征分量方向更连续。边特征构造也从“一条边一个线程”改成“边 × 特征”分工，使 warp 内的写入更连续。

改动	改前	改后	耗时减少
message gather tile	267.7	257.1	4.0%
edge-feature tile	257.5	247.7	3.8%

表内单位均为 **μs/atom/step**；每一行是该实验自己的 clean A/B 中位数，不要求上一行改后与下一行改前完全相等。系统运行噪声、分支快照和实验批次不同，不能把它们强行拼成同一条逐点精确曲线。[D3：相应两个 JSON]

6.4 优化三：张量积里的共同项先算一次

考虑经过适当分组的一条收缩路径，

$$y_{ca} = \sum_b x_{cb} \left(\sum_d C_{bda}\, z_d \right).$$

若z 与固定的C 在这一组里不随 channel c 变化，可先算

$$g_{ba} = \sum_d C_{bda} z_d, \qquad y_{ca} = \sum_b x_{cb} g_{ba}.$$

第一步对相同数据只做一次，第二步让不同 channel 复用g。这里“可复用”有前提：必须在共享相同输入和耦合路径的范围内分组；不能跨不同原子、不同边或不同动态权重随意复用。

本项目还把输出索引展开成连续位置，让相邻线程连续写入，并把部分局部输入保存在寄存器。**收益来自重复工作减少和访问顺序改善，训练权重、耦合路径和计算目标不变。**浮点误差仍需核验。

clean sandbox 两轮数据为 **247.8 → 230.1 µs/atom/step**，完整模型耗时减少 7.1%；所记录 forward 张量积阶段约快 2.22 倍。完整模型与单个阶段的分母不同，不能混用。[D3：sandbox JSON、stage profile]

6.5 优化四：边更新与拷贝融合

edge-up / scatter等步骤中，部分原始到缩放数组的拷贝可以与 cutoff 乘法合并，再通过特征优先的 tile 改善访问。它没有删掉 cutoff，而是把相同乘法放到能减少额外读写的位置。

这组 A/B 的稳定基线轮为 **229.9 µs/atom/step**；候选两轮稳定轮的“轮次中位数的中位数”为 **224.1 µs/atom/step**，减少约 2.5%。这是事后选取稳定轮的探索性统计，全部样本与所有轮次的中位数见下一节。旧稿中的 2.8% 来自不同历史端点，不当作这一次配对实验的精确收益。

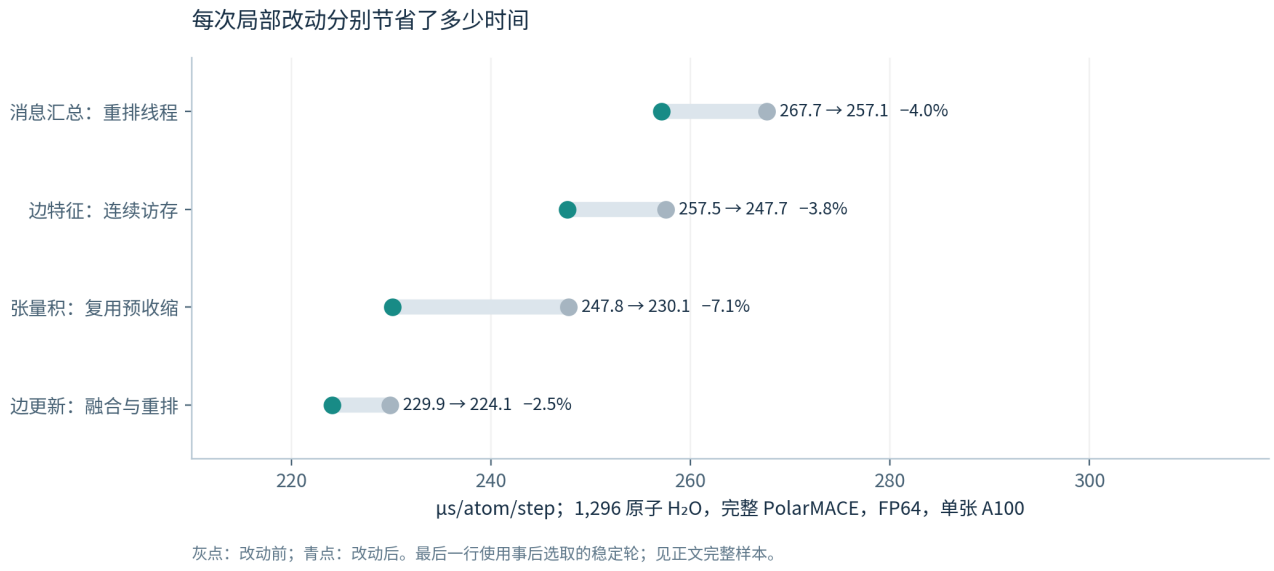


图 6-1 ｜四组局部优化各自的配对结果。由 Python 读取已提交 JSON 并重新计算；前三组采用各自 clean 两轮，最后一组采用已明确标注的事后稳定轮。横向位移表示同一实验的收益；不跨行计算累计倍率。

6.6 慢轮保留：为什么 224.1 与 224.4 都出现

边更新候选记录了三轮中位数，转换后约为 **423.7、224.4、223.7 µs/atom/step**。三轮中位数的中位数为 **224.4**；仅对后两轮稳定轮取中位数得到 **224.1**。旧稿用后者作为稳定值，却把另一套整次调用值和它并列，导致换算不一致。

本教程统一处理为：**全部轮次的统计作为保守记录，稳定轮数值作为探索性估计，两者都报告。**不把第一轮从原始数据删掉；也不把“看起来慢”自动当成已由硬件监控证实的外部争用。

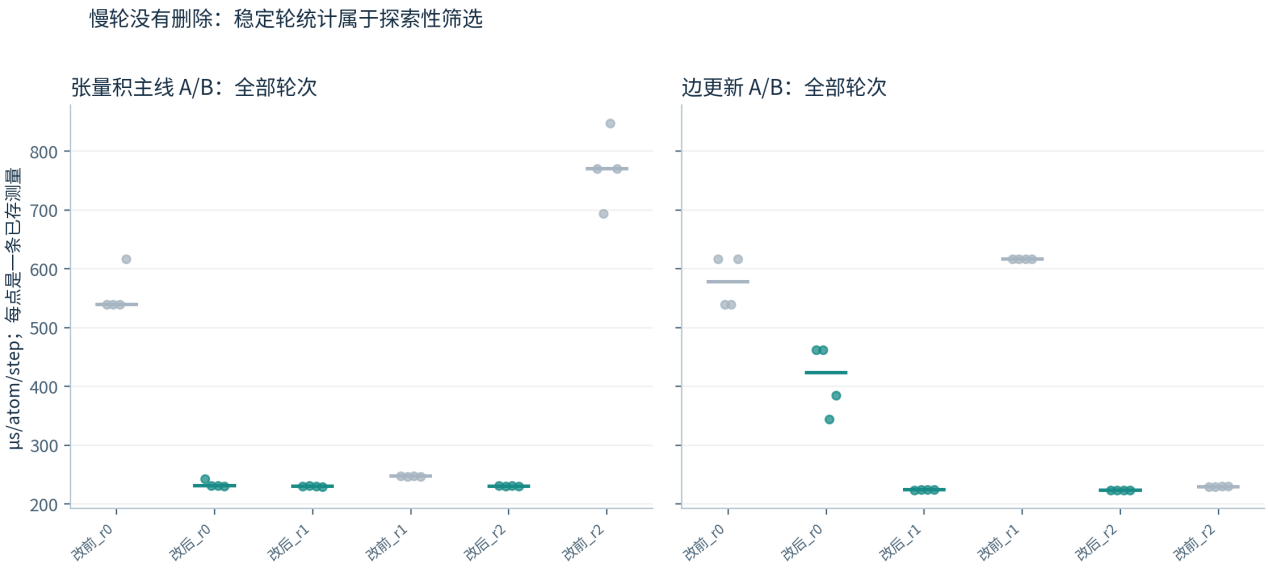


图 6-2 | 两个 A/B 文件内保存的全部单次样本。灰色为改前，青色为改后；短横线为该轮中位数。高耗时轮仍显示，图未使用裁掉异常值后的窄纵轴。单位统一为 μs/atom/step。

主线记录对部分基线轮标注了共享 GPU 争用，clean sandbox 提供了独立的稳定交叉检查。但最终边更新实验仍缺独占硬件的预先固定协议复测。因此目前不为它构造虚假的置信区间，也不宣称只有四个样本就能代表生产环境的波动分布。

6.7 历史上总体做到了什么

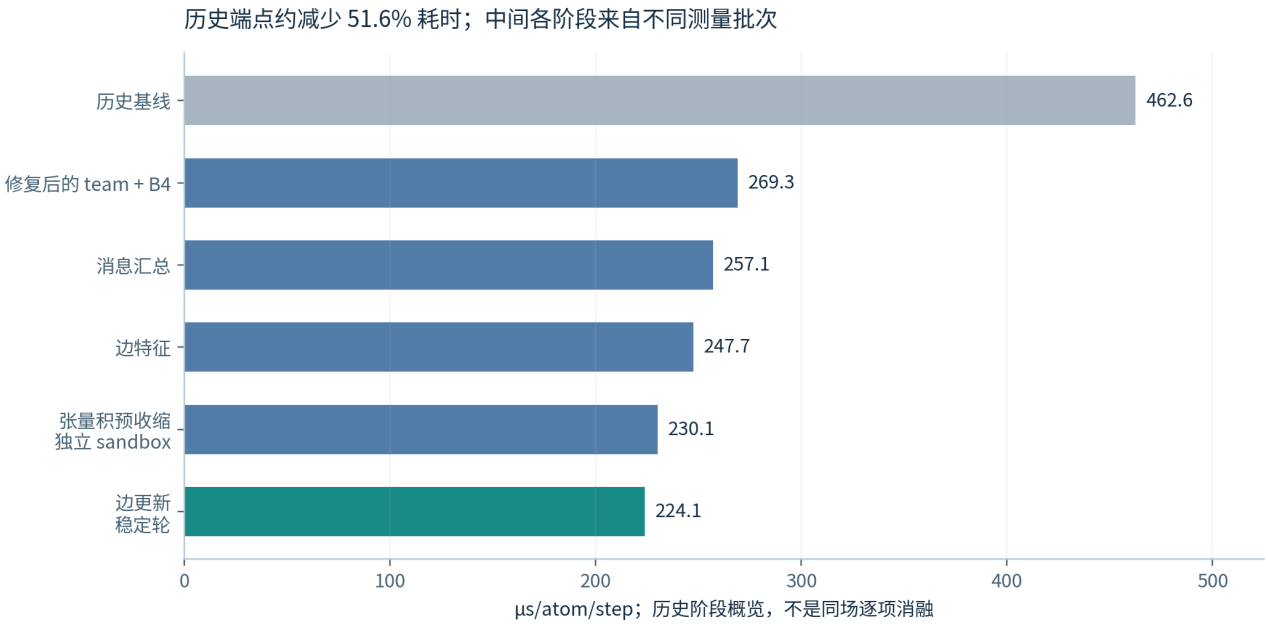


图 6-3 | 1,296 原子水体系的历史进展。历史起点约 462.6，最终稳定轮估计约 224.1 μs/atom/step；耗时约少 51.6%。未修复的 FP64 team 中间版本不列为有效阶梯。中间阶段来自不同实验批次，图用于说明工程进展，不用于精确归因或误差统计。

把两个历史端点相除约为 2.06 倍。它说明这条工程链取得了明显进展，但不等于最后所有开关在同一最终二进制上的同时消融，也不等于已在全部体系上取得相同倍率。

特别要注意：本仓库的 128 原子 Plan B-30ms、1,024 原子旧 round-3 和 1,296 原子水优化链不是同一个版本下的一条规模曲线。不能从其中两个点拟合扩展率，也不能把小体系的最新收益直接乘到尚未重测的大体系上。

6.8 没成功的尝试，也能告诉我们什么

尝试	仓库现象	应怎样理解
两次极化更新改一次	能量差约 1.27 eV，最大力分量差约 0.101 eV/Å	改变模型；不能当作无损加速
channel vec4、部分展开	某些测试变慢	更多寄存器或工作量可能抵消并行收益
不同 team size	结果随配置变化	最优参数依赖任务规模与路径
Random Batch Ewald	收敛趋势可见，但生产力误差门未通过	无偏或渐近收敛不等于有限样本可用于 MD
单 GPU 上增加 MPI rank	正确性可通过，但未证明加速	进程竞争同一设备不等于多 GPU 扩展

这些负结果只针对对应模型、版本和测试设置。“没有找到更快开关”不等于达到数学性能下限；“这个 RBE 配置未通过”也不等于所有随机长程方法都不可能有效。[D1–D5]

专题七：怎样证明算得对，而不是只跑得快

7.1 先问：是和谁比较，比较什么

验证层级	参考对象	主要回答
算子／阶段	固定 Python fixture 与实时原模型	这一段代数和布局是否一致
完整能量和力	同一 PolarMACE 的 PyTorch 输出	引擎是否忠实执行模型
LAMMPS 接口	独立 engine 评估	类型、坐标、周期、力传回是否接对
固定结构重复调用	同一实现的前后调用	缓存、缓冲区和状态是否泄漏
MD 短轨迹	原始引擎同初值轨迹	连续调用与积分时是否出现偏离
模型物理准确性	DFT、其他电子结构方法或实验	这个势是否适合研究目标

不同层级互相补充。某个 kernel 与旧 kernel 一样，不保证旧实现没有共同错误；短轨迹一致也不自动证明长时间热力学正确。

7.2 能量误差、力误差和有限差分

总能量差、每原子能量差、最大力分量差和力 RMSE 的含义不同。本文引用 gate JSON 时保持原定义，例如

$$\Delta E_{\mathrm{abs}} = |E_{\mathrm{engine}} - E_{\mathrm{ref}}|, \qquad \Delta F_{\max} = \max_{i,\alpha} |F_{i\alpha}^{\mathrm{engine}} - F_{i\alpha}^{\mathrm{ref}}|.$$

这里α 为三个 Cartesian 分量；最大分量差不是力向量模长的最大差，也不是力 RMSE。能量总量接近零时，相对误差还可能失去解释力，因此不能只报相对值。

有限差分是独立检查求导链的一种方法，

$$F_{i\alpha}^{\mathrm{FD}} \approx -\frac{E(\mathbf{R} + \delta \mathbf{e}_{i\alpha}) - E(\mathbf{R} - \delta \mathbf{e}_{i\alpha})}{2\delta}.$$

δ 太大有截断误差，太小则可能受浮点相消和求值噪声影响。应扫描合理步长，避免跨越邻居表或其他非光滑分支。有限差分通过说明力与被实现能量一致，不说明该能量对 DFT 一定准确。

7.3 为什么单点通过，第二次调用却可能错

本项目发现过明确的状态 bug：当 write-through 语义要求覆盖输出时，FP64 team forward 却无条件使用加法累积。第一次调用使用刚清零的缓冲区，看起来正确；后面调用把新值加到旧结果上。

$$\text{正确覆盖：} \quad y^{(k)} = F(x^{(k)}), \qquad \text{错误累加：} \quad y^{(k)} = y^{(k-1)} + F(x^{(k)}).$$

固定坐标时，原始 pre-team 引擎连续三次总势能相同；未修复 team 版本从约-49242.46 eV 漂到-48812.11 eV，再变为约4.73×10^{7} eV。修复后固定结构重复输出恢复一致。这里展示错误症状，不把错误版本的速度算作有效生产结果。[D4]

最低限度的回归序列应包括：固定结构连续评估；改变坐标后再评估；恢复原坐标再评估；改变原子数或邻居数的相关路径；随后运行连续 MD。三次固定结构测试很重要，但并不覆盖所有缓存失效情况。

7.4 已有 gate 证明了什么，没证明什么

已提交记录	数值	限定
128原子 LAMMPS 1-rank 对 engine	总能量差约2.91×10^{-11} eV；最大力分量差约2.58×10^{-14} eV/Å	指定 B4team 版本及构型
相同体系 2-rank exact	最大力分量差约1.69×10^{-6} eV/Å	正确性，不是多 GPU 加速
修复后固定结构重复调用	最大力差约10^{-15} eV/Å	对应重复调用序列
10 步 NVE 实现对比	记录中的势能逐步相同；文字记录另报极小位置与力差	仅约 5 fs 的短轨迹
Plan B-30ms	完整阶段、端到端、接口及重复调用门有记录	不自动覆盖 1,296 原子最终分支

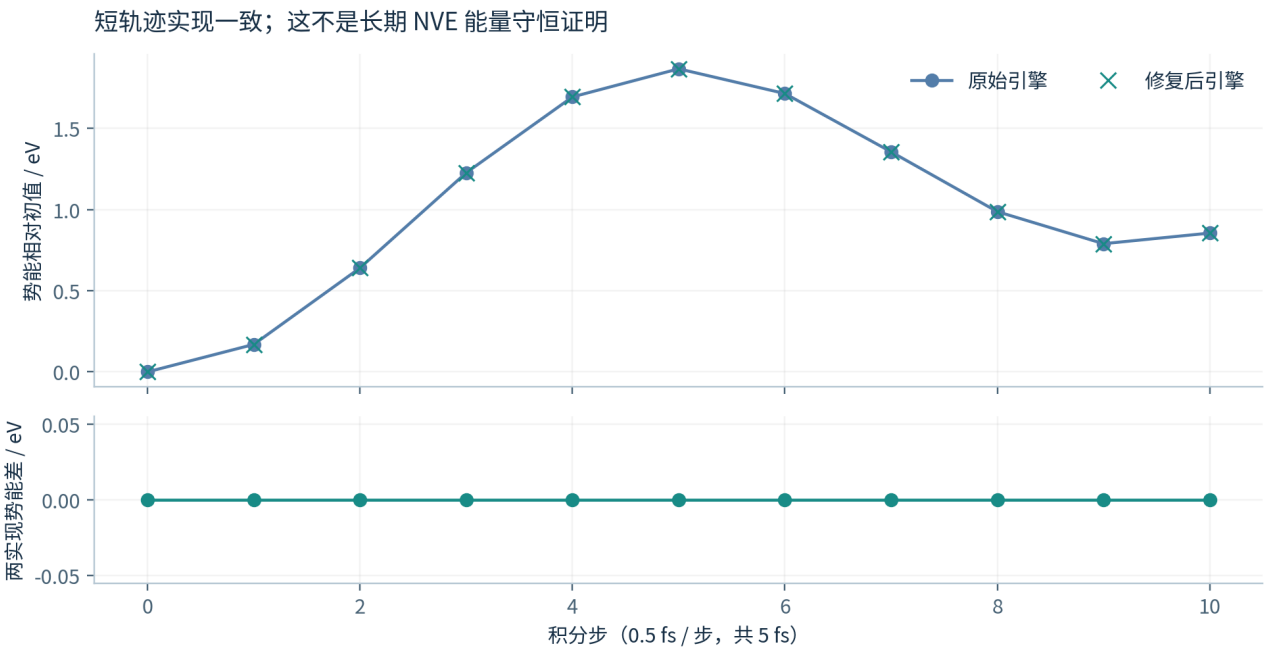


图 7-1 | Python 从 gate_md_10step_128.json 读取的势能序列。上图两条轨迹重合，下图势能差为零。展示的是两实现的势能一致性；纵轴不是 NVE 总能量，也不能用势能自身起伏判定能量守恒。

NVE 总能量需要同时包含动能和势能；势能单独变化在正常动力学中很常见。这份 JSON 只保存势能，没有长期温度、动能、总能量漂移和结构分布，因此不能升级为长期稳定性结论。文字记录中极小的位置和力差也应与 JSON 实际包含的数据区分。

7.5 测试矩阵应该怎样补齐

下一轮应把最终发布二进制与模型身份固定，再按体系、尺寸、边界、精度和 rank 数建立矩阵。同一版本至少覆盖不同扰动构型、固定与变化结构连续调用，以及能量、力和需要用到的应力。记录失败本身也应保留。

若目的是研究电荷转移和极化，还需具体的物理测试：外电场响应、片段解离电荷、总电荷态切换、周期尺寸与截断收敛等。若目的是生产 MD，则增加长轨迹、邻居表重建、温度及总能量漂移、目标结构统计量。门限应由任务需求和数值精度决定，不能为了通过而随意放宽。

本专题检查点。汇报时能把“实现保真”“求导一致”“重复调用正确”“短轨迹一致”“对 DFT 准确”分别说明，而不是用一个 PASS 包揽全部结论。

专题八：结果怎样比较，下一步怎样安排

8.1 两条测试分支分别汇报

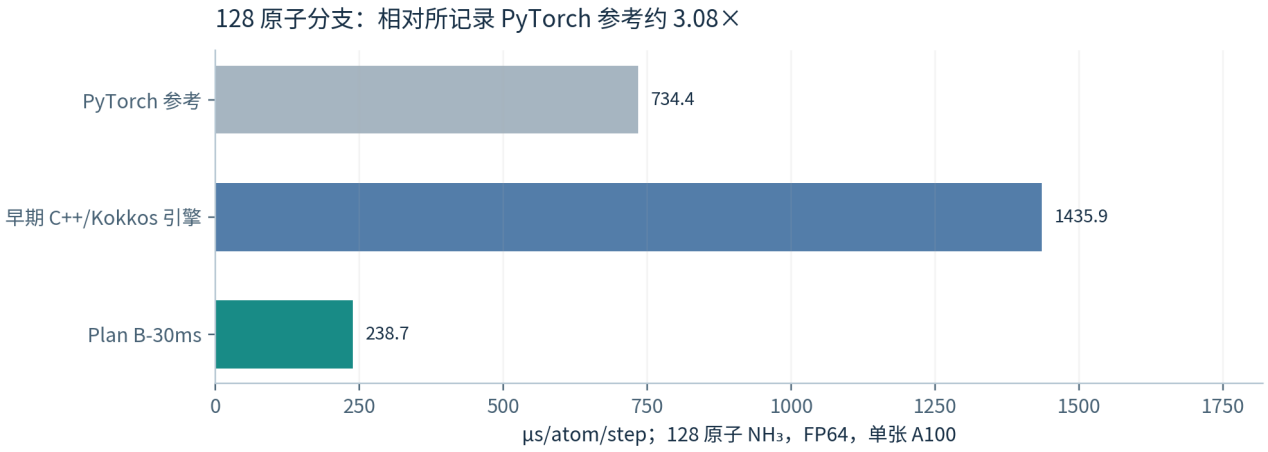


图 8-1 | 128 原子 NH_3 分支的历史参考比较。单位统一为 μs/atom/step，FP64、单张 A100；PyTorch 参考和各历史引擎并非本次在同场重新测量。Plan B-30ms 的原始记录是最终二进制的分轮中位数，见 D1。

这张图回答“当前小体系分支相对已有参考怎样”，不能回答“所有体系都快 3 倍”。**238.7 μs/atom/step** 对应 Plan B-30ms；**734.4 μs/atom/step** 对应所记录 PyTorch 参考，两者历史比值约 3.08。相对早期专用 C++ 引擎约 6.02，也不能把这个比值说成相对原论文 ML-IAP 的加速。

1,296 原子分支来自另一条水体系优化链，目前全部轮次中位数 **224.4 μs/atom/step**、稳定轮估计 **224.1 μs/atom/step**。**不要用 128 与 1,296 两个不同体系、不同快照的归一化数值，推断“规模增大后加速多少”。**完整规模曲线必须固定模型、精度、构型生成规则与最终版本后重测。

8.2 4.50 μs/atom/step 是参照，不是 PolarMACE 的既定目标

原论文 **4.50 μs/atom/step** 来自 MACE-OFF23、水、5,184 原子、FP32、standard streaming。当前 PolarMACE 是另一模型、FP64、materialized，而且原子数也不同。这几个条件同时变化，因此不能把差距全归给“极化物理”，也不能全归给引擎低效。

仓库曾用 MACE-OFF23、水、5,184 原子、FP32 direct/JIT 作对照。三进程结果分别保留最小值与中位数：

试次	最小值	中位数
1	4.53	6.37
2	4.47	4.49
3	4.50	5.43

单位均为 **μs/atom/step**。最小值显示已记录的最快样本可接近论文所报告量级；三进程中位数的中位数为 5.43，且本地短 run 协议与论文完整 Loop 协议不同。因此正确说法是“已记录最快样本接近原论文量级”，**不是“已严格复现原论文中位性能”**。[D5]

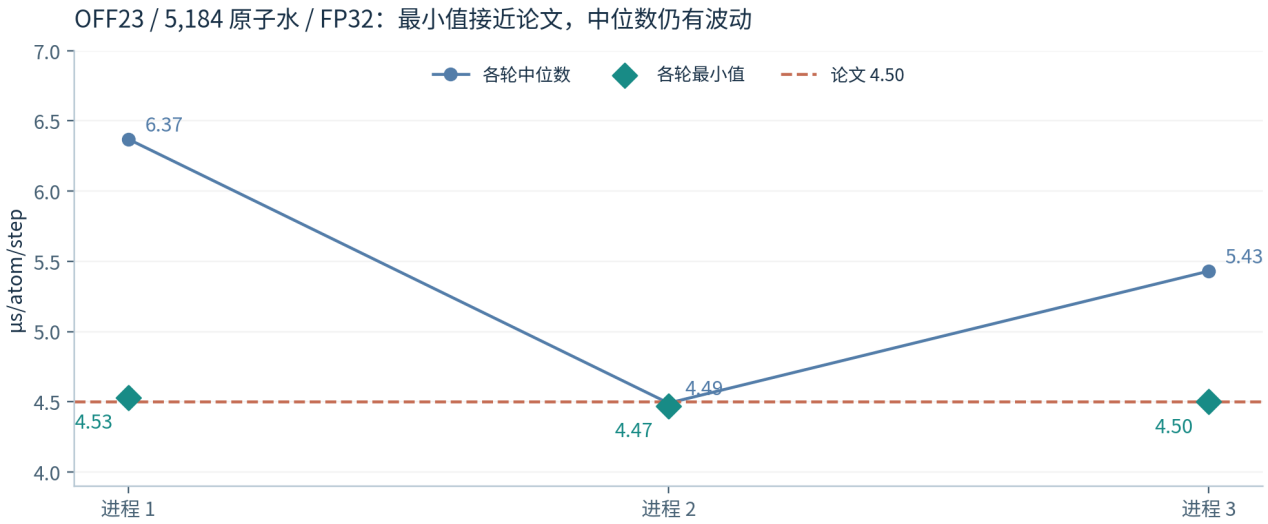


图 8-2 ｜最小值与中位数分开画，避免把每轮最快样本当作典型性能。Python 按仓库已提交的三轮表格重画；原始逐样本 OFF23 日志未随该摘要提交，因此本图不补造误差条或样本分布。

FP32 与 FP64 是数值精度；它们不是模型“线性／非线性”的固有属性。当前接受路径选用 FP64，不等于任何 PolarMACE 计算都在数学上必须使用 FP64。若尝试混合精度，需要重新验证误差、响应、力和轨迹，不能只以速度决定。

8.3 RuNNer 2.0 与本项目，解决的问题有何不同

RuNNer 2.0主要提供小型 HDNNP 的训练与执行，重点优化 CPU 上的全局 QEq、长程静电、缓存和并行。Symmetrix-Polar 主要保留已有 PolarMACE 模型，通过 GPU 引擎执行和优化来降低推理开销。[P4；D1–D5]

两者都讨论全局电荷信息，但不是同一模型、同一数据和同一硬件。RuNNer 的 2G 千万原子演示不能当作其 4G 性能，也不能与本项目的 FP64 full PolarMACE 直接互除。即使某个专用水模型在 CPU 上耗时更低，也不能据此认定它与基础模型具有同样适用范围或预测误差。

若目标是为一个固定体系训练高效势，RuNNer 路线值得考虑；若目标是直接执行既有 PolarMACE checkpoint，本项目处理的是对应的部署问题。**比较应从研究目标出发，再匹配模型误差、原子数、边界、精度、硬件和计时范围。**当前材料不足以给出普适速度排名。

8.4 当前时间花在哪里

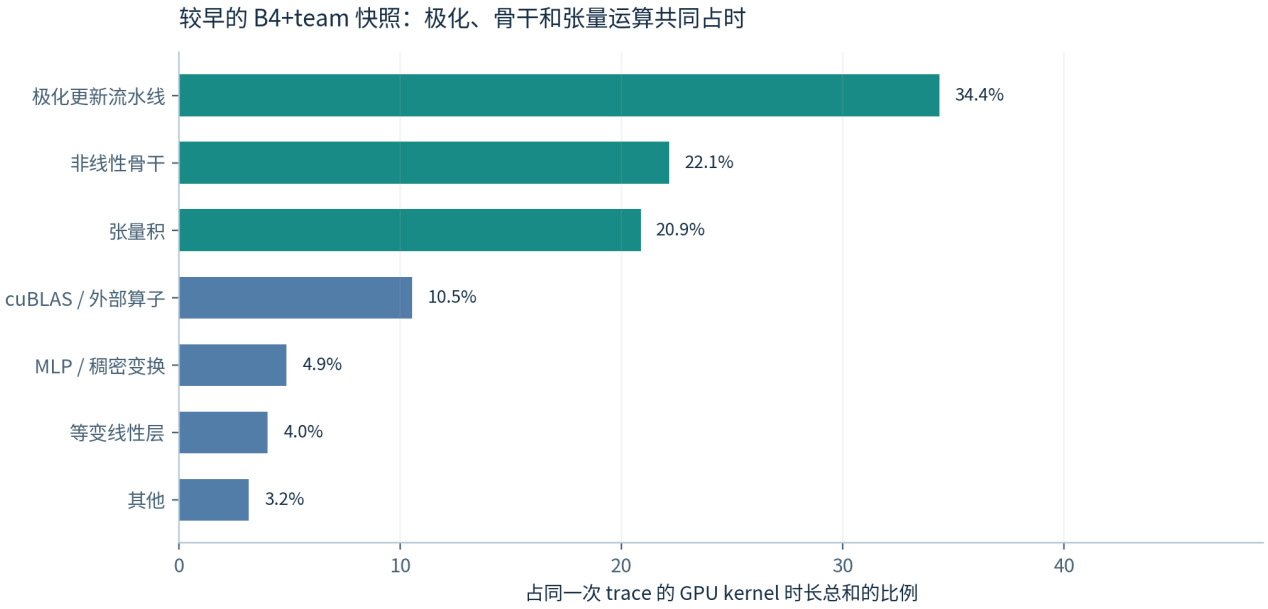


图 8-3 | 较早 B4+team 版本的一次 CUPTI 快照，按互斥 family 分类。分母是该 trace 的 GPU kernel 时长总和；不是最终优化版本的最新 profile，也不是 CPU 到 GPU 的端到端耗时。数据来自 cupti_b4team_1296_summary.json。

图中极化流水线、非线性骨干和张量积都占有明显比例。不能从“有 Ewald”推断长程库仑一定是主瓶颈；也不能把旧版本的分类比例拿来精确预测新版本优化收益。每一次较大优化后，应重新 profile，因为原来的次要部分可能成为新的主瓶颈。

对于没有硬件计数器支持的算术强度、带宽或 occupancy 解释，本教程保留为假设。下一轮要先用时间分解确定候选，再通过 A/B 和硬件信息验证，避免按看起来最复杂的公式盲目优化。

8.5 按优先级安排下一轮

优先级	实际动作	通过条件
1	固定最终模型、二进制、编译选项与开关	有完整身份记录，可重新构建
2	独占 GPU，预先固定 warm-up、测量步数与重复进程	报中位数与分布，不事后挑最快轮
3	同一最终版本重跑 128、1,024、1,296 及容量边界	区分体系与模型，不混合版本
4	对最终版本补齐阶段、端到端、重复调用、MD 和应力验证	数值门与测试范围明确
5	在最新 profile 上优化局部热点	全模型收益与数值保真同时通过
6	研究 PolarMACE 边算子的 tiling ／ streaming	峰值内存下降，新增重算可接受

“还可优化多少”目前没有经过最终版硬件测量证明的理论下限。旧报告提出的“现实终点 200–215”以及“4.5 只能改模型才能达到”等说法，均不应当作确定结论。先完成统一测量和依赖分析，再讨论上界。

本专题检查点。读者应能用一张表说清当前结果、比较条件与证据缺口，而不把“论文容量”“本地最快样本”“当前稳定轮”和“最终生产性能”混为一谈。

附录 A：公式串起来看一遍

本附录只保留理解完整链路所需的骨架；具体通道、基归一化、单位换算、截断和边界条件以模型与接口定义为准。

第一步，局部几何编码。位置和元素经有限层 MACE 得到节点特征及局部能量：

$$(\mathbf{R}, \mathbf{Z}) \longrightarrow \{\mathbf{h}_i\}, \quad E_{\text{local}}.$$

第二步，初始化密度并满足总量。从节点特征读出原子多极，使用两个自旋通道的 Fukui 平衡。它保证规定的单极之和，不改变更高多极的定义：

$$p^{\sigma}_{i,00} = \tilde{p}^{\sigma}_{i,00} + \frac{f^{\sigma}_i}{\sum_j f^{\sigma}_j} \left(Q^{\sigma} - \sum_j \tilde{p}^{\sigma}_{j,00} \right).$$

第三步，执行固定数目的全局更新层。密度产生全局场，场特征与局部几何一起更新多极，再做归一化。对当前模型保留两层；不把它改成未经训练的收敛迭代。

第四步，计算三部分能量并对完整链求导。

$$E = E_{\text{local}} + E_{\text{nonlocal}} + E_{\text{electrostatic}}, \qquad \mathbf{F}_i = -\frac{dE}{d\mathbf{R}_i}.$$

这里写全导数强调所有依赖都需考虑。若把$\mathbf{p}$ 当作中间变量，教学展开为

$$\frac{dE}{d\mathbf{R}_i} = \left.\frac{\partial E}{\partial \mathbf{R}_i}\right|_{\mathbf{p}} + \sum_a \frac{\partial E}{\partial p_a} \frac{dp_a}{d\mathbf{R}_i}.$$

a 汇总所有原子、通道与多极分量。$\mathbf{p}$ 在这里代表把网络内部几何、场更新等依赖复合后的中间量；实际求导还需覆盖局部能量及其他路径，不能只实现这个示意式中的一部分。

第五步，MD 积分。用力推进坐标，更新必要的邻居表，然后进入下一次模型评估。GPU 缓存若依赖位置、晶胞或图，就必须按这些输入的变化正确刷新。

附录 B：符号与术语速查

B.1 数学符号

符号	含义	易混点
N、N_e	原子数、有向边数	N_e 不是电子数
$\mathbf{R}_i$	第i 个原子的位置	与旋转矩阵区分
r_c、skin	模型截断、邻居表额外厚度	不都属于模型有效作用半径
l, m	旋转表示阶数及分量	不是代际与网络层数
p	某些表示式中的反演奇偶性	与多极系数$p_{i,lm}$ 按上下文区分
$C_{l,p}$	某类特征的通道数	不是几何空间维数
Q	总净电荷	不等于原子电荷绝对值之和
S、M	论文通道归一化差、接口可能使用的多重度	先查约定再换算
ρ^{σ}	自旋分辨的平滑残余电荷密度	不是完整 DFT 电子密度
$p^{\sigma}_{i,lm}$	原子中心多极系数	单极、偶极与高阶系数意义不同
f_i, w_i	Fukui 特征、归一化响应权重	具体生成与稳定处理由模型定义
$\Omega, \mathbf{k}$	晶胞体积、倒格矢	Fourier 前因子依赖定义
θ	训练后固定的模型参数	与每条边动态生成的中间权重不同
u	归一化性能数值	全文单位为 μs/atom/step

B.2 常见英文名称

名称	中文解释
checkpoint	已训练模型的参数及相关定义
inference	固定参数后求能量、力等输出
equivariance	输入变换时，输出按规定规律变换
irrep	不可约表示；按旋转与反演规律组织特征
readout	从内部特征生成能量或其他输出
tensor product	按几何规则组合等变对象
multipole	单极、偶极等电荷分布描述
polarization	电场引起的电荷分布重排
charge transfer	指定分区下的片段净电荷交换
QEq	通过电荷能量泛函及约束求电荷的模型族
SCF	self-consistent field；本仓库历史名称不等于原模型做收敛求解
Ewald / reciprocal space	周期静电求和／倒空间组织
materialized	把中间量显式保存成数组
streaming	中间量就近生成、使用后释放
tiling	分块执行并复用工作区
JIT / specialization	按模型结构生成并编译专用算子
gather / scatter	从多处汇总／把结果分配回对应位置
adjoint / reverse mode	伴随量／由输出向输入传播导数
parity gate	与参考结果的数值一致性检查
OOM	out of memory；分配所需内存失败
A/B	保持其他条件尽量一致，比较单项改动

附录 C：开会时可以直接使用的问答

问：你们训练了一个新势吗?
答：这里主要做引擎扩展和执行优化。目标是在指定误差内保留已有 PolarMACE 的预测，而不是重新训练、蒸馏或删掉物理项。

问：PolarMACE 与普通 MACE 差在哪里?
答：除了局部几何，它还学习平滑的自旋电荷多极，通过全局电势更新这些特征，满足总电荷／自旋约束，再计算局部、非局域与静电能量。

问：两次 SCF 迭代就收敛了吗?
答：原模型不是迭代到收敛的 SCF。它使用两次学习型极化更新；两层是模型定义的一部分，不能把层数当求解精度开关。

问：为什么 GPU 还慢?
答：当前路径有宽边数组、张量收缩、许多局部网络及反向步骤。GPU 需要合适的线程和访存组织；只把计算搬上 GPU 不会自动消除重复工作和中间存储。

问：你们最主要改了什么?
答：让线程更连续地访问特征，把共同的张量积收缩先算一次复用，融合部分反向汇总与拷贝，并修复连续调用的状态错误。每项收益看自己的配对数据。

问：现在多快?
答：在指定 A100、FP64 配置下，128 原子分支为 238.7 μs/atom/step；1,296 原子水分支全部轮次中位数为 224.4，稳定轮估计为 224.1 μs/atom/step。它们不是同一规模曲线。

问：已经和论文一样快了吗?
答：普通 OFF23 路径的已记录最快样本接近论文量级，但中位性能和计时协议仍有差别；full PolarMACE 是另一模型，不能直接与论文 4.50 的点对比。

问：正确性有没有问题?
答：已有阶段、能量／力、接口、重复调用及短轨迹检查；发现过的 write-through bug 已有修复记录。完整最终版本仍应按尺寸和边界做统一复验，不能把已有小体系 gate 泛化到所有场景。

问：下一步最值得做什么?
答：先在独占 GPU 上固定最终版本和统一测速协议，再根据最新 profile 优化热点；同时研究边工作区分块，解决容量。没有证据支持先承诺某个 “理论终点”。

附录 D：本版改正了旧报告哪些问题

旧说法或表达问题	本版处理
PolarMACE是 “Fukui 平衡的 SCF 不动点”	改为固定两层非自洽学习型极化更新；代码旧称另说明
能量项命名不统一	对照原论文采用 local、nonlocal、electrostatic 三部分
密度 Fourier 已含 Gaussian，又另乘 screening	明确 Fourier 约定，说明避免重复衰减
普通 MACE 都是线性的、没有动态权重	区分工程路径、内部算子、readout 与模型非线性
全局密度意味着任何 streaming 都不可能	改为当前实现限制，说明可研究的局部分块
l、通道维数、网络代数混称	分别解释，并提供 2048/8192 的算例
32 倍写放大	改为 FP64 单指令 sector 算例及适用前提
静态 occupancy 当成实测利用率	明确推算性质及硬件计数器缺口
单算子快 2.22 倍与全步收益的分母混用	补 Amdahl 算例，实际收益使用 clean A/B
未修复 team 版本也作为有效优化阶梯	从有效历史图剔除，并保留故障解释
多处整次时间与归一化数值不一致	从 JSON 重算，区别 224.1 与 224.4 的统计
4.50 被当成 full PolarMACE 的理论下限	改为不同模型和路径的外部参照
最快样本代表典型性能、短轨迹代表长期稳定	保留全部样本，区分最小值／中位数及验证层级
未核实 “唯一引擎”、确定的最终性能预测	删除这类超出证据的结论

附录 E：文献、图源与复算入口

E.1 原始文献

[P1] Fu, L. 等。*Train for Accuracy, Execute at Scale: Architecture-Preserving Inference for Equivariant Atomistic Foundation Models*。arXiv:2610.01036v1，2026。原文与版本。本文执行图来自原图 1，速度图来自原图 2，容量图来自原图 3。它们按原样提取并给出中文阅读说明，没有把原论文结果改成仓库新结果。

[P2] Batatia, I. 等。*MACE-POLAR-1: A Polarisable Electrostatic Foundation Model for Molecular Chemistry*。arXiv:2602.19411v1，2026。原文与版本。重点依据 §II、原图 1 及 SI V.F；HTML 与 PDF 的小节标号略有不同，本文同时给出标题或式号。图中应用精度属于原文证据。

[P3] Batatia, I. 等。*MACE: Higher Order Equivariant Message Passing Neural Networks for Fast and Accurate Force Fields*。NeurIPS 2022；arXiv:2206.07697。用于 MACE 的高体阶消息、等变表示与局部原子能的基础概念。

[P4] Knoll, A. L. M. 等。*RuNNer 2.0: A software suite for high-dimensional neural network potentials*。J. Chem. Phys. **165**, 152502 (2026)。DOI:10.1063/5.0352886。只用于讨论另一类软件路线与比较条件；本教程不建立其与 PolarMACE 的同条件速度排名。

图片使用说明。原论文图用于本教程的学术讲解与来源对照，作者及来源见每幅图注；原图权利归相应作者或权利人，不因本仓库代码采用 MIT 许可而改变。AI 概念插图不含真实计算数据，提示词与用途记录在 image_provenance.json；Python 数据图均有对应数据入口。

E.2 仓库证据索引

下列路径相对仓库根目录。历史文件可能含已过时措辞；本教程只按明确的文件、版本、统计定义引用，不把旧的汇总结论直接视为新的验证。

编号	内容	文件
D1	128原子最终计时、最终二进制、阶段及重复调用门	PLAN_B_30MS_FINAL.md
D2	1,296 原子历史优化链与来源索引	OPTIMIZATION_LEDGER.md
D3	所有 A/B、sandbox、计时分轮、gate 摘要	data/README.md
D4	FP64 team 改动与 write-through 故障、修复及短轨迹文字记录	MH1_TEAM_FP64.md
D5	OFF23 对照、精度、路径、规模、原论文协议差别	PAPER_COMPARABILITY.md
D6	本版由原始摘要重新派生的数值和选择规则	derived_metrics.json
D7	所有 Python 数据图的生成方法	build_tutorial_figures.py
D8	PolarMACE 引擎支持及部分布局实现	polar support patch

本教程依据的代码仓库输入快照为 **5cdf8a0fd37209a777cb4b47fac5f5e813a0db0f**。这个哈希标识编写起点，不是 GPU 运行二进制身份；各测试自己的身份见相应记录。derived_metrics.json 保留本版构建时的输入 commit、筛选规则与重算值。

E.3 复算应做什么

重新生成数据图：在仓库根目录运行 Python 脚本 harness/build_tutorial_figures.py。它只读取已提交 JSON 和有来源的历史表格，不补造 benchmark 数据。重新生成 PDF 与离线网页：运行 harness/build_tutorial.py。

原始 GPU 日志、完整 trace、checkpoint 和某些探针输入不全部包含在公开提交中，因此仅靠这个阅读包不能重新执行所有历史 GPU 实验。可复算的是已提交摘要的统计、单位换算和图表；真正重跑需要补齐模型、环境、二进制和输入身份。两类“复现”必须区分。

读完后应带走的判断方法：先确认模型在计算什么，再检查引擎实际执行了什么；先固定比较条件，再解释速度；先明确验证参考和范围，再讨论正确性。这样既能讲清当前工作，也能知道下一步还需要什么证据。