Symmetrix-Polar
技术报告

非线性极化力场的 GPU 内核优化
理论 · 实现 · 实测结果 · 局限 · 复现

128 原子（32 NH3），full PolarMACE	48.74 ms/eval
1024 原子（256 NH3），full PolarMACE	312.1 ms/eval
相对 round 2 / v29 Kokkos 引擎	1.159× / 3.77×
全套数值门	PASS
RBE 生产精度门	REJECTED

版本：round 3 final · 2026-10-20
模型：MACE_Nonlinear + PolarMACE，FP64，单张 A100-80GB
本 PDF 由 Markdown 源文件自动生成，可直接续写。

目录

摘要 3
0. 三分钟读懂与术语表 3
0.1 这个项目在做什么 3
0.2 关键术语 3
0.3 记号 3
1. 背景：为什么需要 GPU 内核优化 3
2. 理论部分 4
2.1 MACE 非线性 backbone 4
2.2 极化长程层 4
2.3 力与反向模式 4
2.4 张量代数与 kernel 映射 4
2.5 Random Batch Ewald（RBE） 5
3. 引擎实现 5
3.1 Symmetrix-XL + Kokkos 5
3.2 LAMMPS pair style 5
3.3 Kernel 家族与几何 5
3.4 数值验证体系 6
4. 优化方法 6
4.1 测速协议 6
4.2 三轮优化概览 6
4.3 Round 3 切片：哪些有效，哪些无效 6
4.4 Kernel 归因 7
5. 实测结果 7
5.1 128 原子（32 个 NH3 分子） 7
5.2 系统尺寸 8
5.3 引擎比较（最新测量） 9
5.4 数值门（round-3 最终 build） 10
6. RBE：为什么没有通过 10
7. 未完成与不足（诚实清单） 11
8. 复现指南 11
8.1 构建 11
8.2 运行 12
8.3 Round-3 环境开关 12
8.4 关键产物 12
9. 如何续写本文档 13
附录 A：关键公式速查 13
附录 B：门限与最终数值 13
附录 C：文件索引 13

摘要

版本： round 3 final · 2026-10-20 适用读者： 第一次接触 PolarMACE / Symmetrix-XL / GPU 内核优化的研究者与工程师

在 128 原子（32 个 NH3 分子）的 full PolarMACE 上，单张 A100 的能量+力评估从 round-2 的 56.50 ms 降到 48.74 ms，全部数值门 PASS；1024 原子（256 个 NH3 分子）为 312.1 ms/eval。20–30 ms 的目标尚未达到，剩余瓶颈和未完成项 在第 7 节明确列出。

0. 三分钟读懂与术语表

0.1 这个项目在做什么

PolarMACE 是一个非线性、可极化、带长程静电的机器学习势（MLIP）。普通 MACE 只看每个原子周围几埃的局部环境；PolarMACE 额外学习每个原子的多极电荷密度， 并用 Ewald 方法计算长程库仑相互作用，再通过自洽迭代（SCF）让密度和势互相一致。 这个项目把 PolarMACE 从 PyTorch 参考实现搬进 Symmetrix-XL 这个 C++/Kokkos GPU 引擎，并把它接到 LAMMPS 的 pair_style，使它能直接跑 MD。

本文记录的是内核优化：不改变物理模型、不降精度（始终 FP64），只改 GPU 上 每个 kernel 的组织方式。

0.2 关键术语

术语	含义
MACE / MACE_Nonlinear	非线性等变神经网络势；节点和边特征经过多层 MLP 与张量积更新
PolarMACE / MACE-POLAR	在 MACE 上增加可极化长程静电层的模型
irreps / l / 2l+1	旋转群不可约表示；一个 l 块有 2l+1 个分量
e3nn linear	对每个 l 块做通道混合的线性层（本质是块对角 GEMM）
MH-1 tensor product	本项目里的稀疏张量积快速路径，把边谐波与节点特征收缩
UVU	极化层里的张量积（l×l→0 与 l×0→l 两种模式）
GTO	Gaussian-type orbital，密度基函数
Ewald	把 1/r 库仑拆成实空间 + 倒空间（k 空间）求和
SCF	自洽场迭代：密度 → 势 → 密度，直到收敛
Fukui	用于初始化/校正电荷与自旋密度的量
Kokkos	性能可移植 C++ 并行运行时；CUDA 后端下 MDRangePolicy/TeamPolicy 映射到 CUDA kernel
CUPTI	CUDA Profiling Tools Interface；用来逐 kernel 计时
RBE	Random Batch Ewald，随机分批采样 k 空间的近似 Ewald
RMS_F	力的均方根误差，单位 eV/Å
Gate	数值验收门；不过门的结果不进入生产

0.3 记号

- 体系：128 原子 = 32 个 NH3 分子，14.736 Å 立方周期盒。
- 模型：polar_symmetrix_probe.json，270 MB，83 元素，r_cut = 6 Å，FP64。
- 时间单位：ms/eval 表示一次能量+力评估的 LAMMPS Loop time。
- 频率/时间步：1 fs = 1e-3 ps；2 ps = 2000 步（1 fs）或 4000 步（0.5 fs）。

1. 背景：为什么需要 GPU 内核优化

机器学习势的 MD 需要每一步都计算能量和所有原子的力。一个 128 原子的体系看起来 很小，但 PolarMACE 的计算量集中在：

- 1. 非线性 backbone：每个原子、每条边的多层 MLP 与张量积；
- 2. 长程极化层：多个 SCF 迭代，每次都要做 k 空间求和；
- 3. 反向模式求力：前向的每个操作都要走一遍伴随（adjoint）。

在 CPU 上，这些操作是数百毫秒到数秒级；在 A100 上，经过内核优化可以做到几十 毫秒。关键不是“GPU 快”，而是每个 kernel 是否有足够的并行度、是否被内存带宽 限制、是否被 launch 开销拖住。

Symmetrix-XL 已经是一个成熟的 Kokkos/CUDA 引擎。本项目的优化不是重写引擎，而是 在它已有的 kernel 家族里，逐项消除低覆盖率、重复工作、零填充和全局读写。

2. 理论部分

2.1 MACE 非线性 backbone

MACE 把体系表示成一张图：原子是节点，r_cut 内的原子对是边。每个节点有标量 特征和等变特征（按 l 分块，每块宽度 2l+1），每条边有径向基函数和球谐函数。 一层 interaction 大致做：

- 1. 边特征与节点特征拼接，经过 MLP 得到每条边的消息；
- 2. 用张量积把边谐波与节点特征耦合，得到消息的等变分量；
- 3. 对每个节点聚合来自邻居的消息（gather/scatter）；
- 4. 经过残差、LayerNorm、SiLU、门控和 readout。

“非线性”指的是这些 MLP/门控/readout 是非线性的；它和“线性 MACE”（线性 readout）是不同模型，不能直接比较绝对时间。

2.2 极化长程层

PolarMACE 给每个原子学习一个多极（电荷/自旋）密度。密度用 GTO 基展开，长程 库仑能写成 Ewald 分解：

E_ coul = E_ real + E_ k + E_ self

倒空间部分（k 空间）是：

E_ k = (2π)/(V)Σ_k≠ 0 |ρ(k)|^2k^2

其中 ρ(k) 是 GTO 密度的傅里叶变换，带有形式因子 exp(-k^2σ^2/2) 和 k^l 多项式。Ewald 的 k 空间求和是长程相互作用的 核心，也是内核优化的重要目标。

自洽场（SCF）：密度决定势，势又决定密度。模型通过若干次更新块迭代到不动点。 每次 SCF 迭代都要重新计算 k 空间量，因此 k 空间 kernel 的成本会乘以 SCF 步数。

Fukui 初始化/校正：用 Fukui 函数把电荷/自旋密度初始化，并在每一步做校正， 使 SCF 更稳定、更接近参考实现。

2.3 力与反向模式

力是能量对原子位置的负导数。PolarMACE 的力需要穿过：

- MACE backbone 的每一层；
- 极化层的 SCF 不动点（隐函数/展开求导）；
- k 空间求和与 GTO 几何因子；
- 边 gather/scatter。

项目里用反向模式伴随逐段实现，并用有限差分（FD）和 PyTorch 参考做双重验证。 round-2 定位并修复了描述符反向里缺失的 *project-phase adjoint*，这是力精度的关键。

2.4 张量代数与 kernel 映射

数学操作	引擎 kernel	优化难点
e3nn linear（块对角 GEMM）	e3 linear pack + cuBLAS GEMM + unpack	小 GEMM、pack/unpack 的 launch 与转置开销
MH-1 tensor product（前向）	e3 tensor product mh1 fused	每个输出只有少量非零 Wigner 项，标量指令/写带宽受限
MH-1 tensor product（反向）	reverse mh1 fused channels/harmonics	全局 read-modify-write、通道维归约
UVU 张量积	polar uvu mode0/1 及反向 x1/x2	低覆盖率、重复读权重/mixed_bar
边 gather/scatter	gather edge message(s) 等	纯内存 gather，难并行化但可融合
MLP / LayerNorm / SiLU	affine fused layer norm silu 等	一行一线程导致串行
k 空间投影/反投	polar desc ab reverse、desc proj phase 等	每个 k/节点的串行归约

2.5 Random Batch Ewald（RBE）

RBE 把 k 空间求和换成随机估计：从分布 q(k)∝ e^-σ_q^2k^2/2 采样 p 个 k 向量，用重要性权重

E_k = (1)/(p)Σ_i=1^p (f(k_i))/(q(k_i))

来做无偏估计。它的误差按 1/√ p 下降，但每个构型只采样 p 个 k 向量， 所以单点力有随机噪声。第 6 节会给出实测和为什么它没有通过生产门。

3. 引擎实现

3.1 Symmetrix-XL + Kokkos

引擎用 C++20 和 Kokkos 编写，CUDA 后端下：

- Kokkos::parallel_for + MDRangePolicy<Rank<2/3>> 映射到二维/三维 CUDA 线程块；
- TeamPolicy 映射到 CUDA block，team_scratch 映射到 shared memory；
- 所有模型参数和激活都是 FP64；没有 FP32/TF32 路径。

项目的私有构建目录是 symmetrix/build-kernel-r3，使用 CUDA 12.9、sm80、Kokkos_ENABLE_IMPL_VIEW_LEGACY=ON。最终二进制 sha256 为 c7608f35845548ef037341833c138da87515484ce51c04a257a5920bb9424631。

3.2 LAMMPS pair style

pair_style symmetrix/mace/kk 把 LAMMPS 的原子数据、cell、节点位置传给引擎，并把引擎返回的能量、力和维里加回 LAMMPS。单 rank 下它使用局域+ghost 图； 多 rank 的 H1 模式在单独的工作流里处理（第 7 节）。

3.3 Kernel 家族与几何

round-3 把反向改成每线程 4 个 channel，并在寄存器里累加。

shared memory；round-3 把反向的 v/u 归约拆成 4 个 chunk，用第二个 kernel 确定 性求和。

用 parallel_reduce 做均值和方差，再并行写回。

拆成 4 个 chunk，第二个 kernel 按 chunk 升序折叠。

unpack 合并成一个 block-plan kernel，但在多贡献 block 上有非法内存访问，默认关闭。

- MH-1 前向/反向：MDRangePolicy<Rank<2>>，每个线程负责一个 (edge, channel)；
- UVU：TeamPolicy，每个 team 负责 64 个节点 × 4 个通道；权重 tile 放在
- Affine MLP：LayerNorm+SiLU 原来一行一线程，round-3 改成一个 team 一行，
- k 空间：polar desc ab 和 desc proj phase 原来一个 k/节点串行，round-3
- e3 linear：pack → KokkosBlas::gemm（cuBLAS）→ unpack；round-3 尝试了把

3.4 数值验证体系

每个阶段都有独立的数值门：

- 1. Frozen fixtures：PyTorch 参考导出的 40+ 个中间张量；
- 2. stage gates：引擎与 fixtures 逐张量比较；
- 3. live reference：现场重新跑 PyTorch 参考；
- 4. end-to-end：32 帧能量/力；
- 5. LAMMPS parity：pair style 与 Python 引擎一致；
- 6. 有限差分：解析力与 FD 力一致。

只有全套门 PASS 的构建才进入“最新 gate-passing 版本”。

4. 优化方法

4.1 测速协议

A/B 不依赖不同的 LAMMPS/Kokkos 构建。

- 同一二进制、同一 session、同一 A100；
- 交替 A/B：baseline、candidate、baseline、candidate；
- 1 warmup + 12 次测量 × 2 轮，取每轮中位数的中位数；
- 所有 GPU 运行都在 flock /workspace/group/shared/bza/.tmp/gpu.lock 下；
- 用 CUPTI 逐 kernel 计时，确认 wall 的收益与 kernel 的收益一致；
- 同二进制回退：每个 round-3 切片都有环境变量能恢复 round-2 路径，所以

round-2 的教训：一个“已验收”的二进制可能链接了旧 object，实际在跑老 kernel。
所以每轮必须强制重编、记录源码时间、object 时间、kernel 名字和最终二进制 hash。

4.2 三轮优化概览

轮次	主要工作	128 原子 full PolarMACE
v28 初始	PyTorch 参考移植到引擎	6951.7 ms
v29	引擎功能/正确性完成	183.8 ms
Round 1	e3nn linear packed GEMM、polar dense reverse	122.2 ms
Round 2	UVU/team kernels、project kernels、stale object 修复	56.50 ms
Round 3	MH-1/UVU/affine/k-space 细化、gate 全套复跑	48.74 ms

4.3 Round 3 切片：哪些有效，哪些无效

有效（保留）：

只 load/store 一次，entry 顺序不变；4.29 → 2.66 ms。

- MH-1 反向通道 4-channel 寄存器累加：每个 (channel,a) 在每个 instruction
- MH-1 harmonics 4 路 ILP：3.10 → 2.45 ms。

- Affine LayerNorm+SiLU team-per-row：正反向合计 2.80 → 0.88 ms。
- UVU reverse x1 分块归约：3.21 → 2.75 ms。
- k 空间 desc ab / desc proj phase 分块：合计 1.89 → 0.30 ms。
- MH-1 前向写穿输出：去掉 zero-fill 和 read-modify-write，约 0.11 ms。
- UVU 前向分块：1.20 → 1.09 ms。

实测变慢（改回 scalar 默认，保留 opt-in）：

MATOS_CONV_CUTOFF_BACKEND=chunked 才启用。

- MH-1 前向 4-channel：4.04 vs 3.34 ms；默认 MATOS_MH1_FWD_CHANNEL_VEC=1。
- Reverse convolution cutoff 两阶段：2.87 vs 1.53 ms；默认 scalar，

中性：

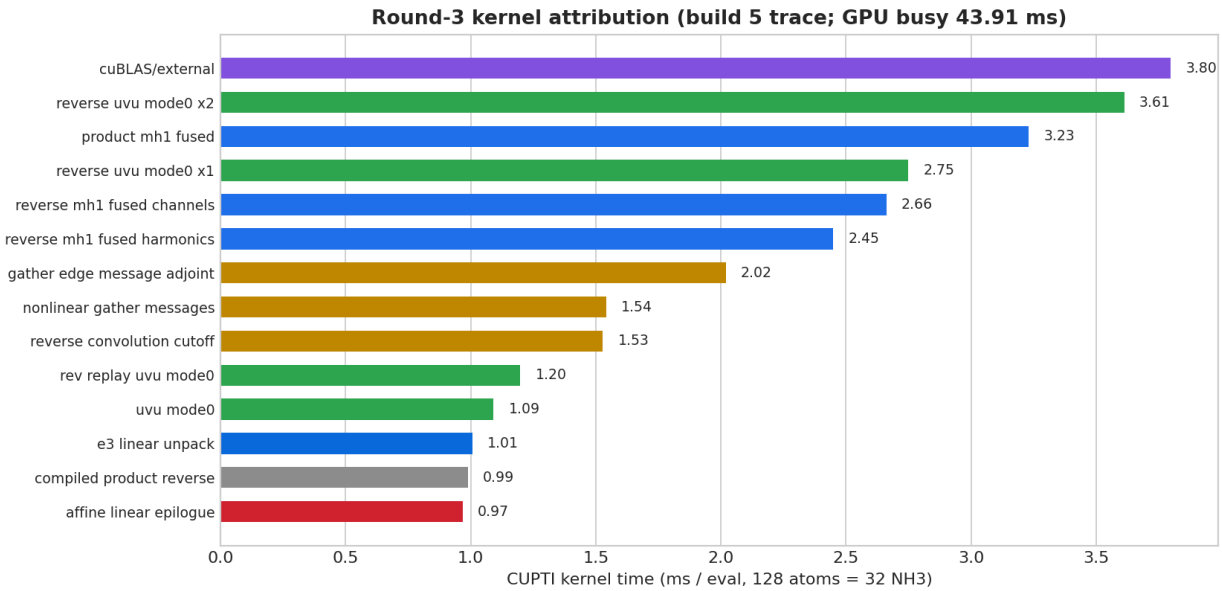
- UVU reverse x2 分块：3.55 → 3.61 ms；瓶颈是 mixed_bar/权重带宽，不是覆盖率。

未完成：

illegal memory access；默认关闭（MATOS_E3_LINEAR_MERGED_UNPACK=1 才启用）。

- e3-linear merged unpack：block-plan 版本在多贡献 output block 上触发

4.4 Kernel 归因

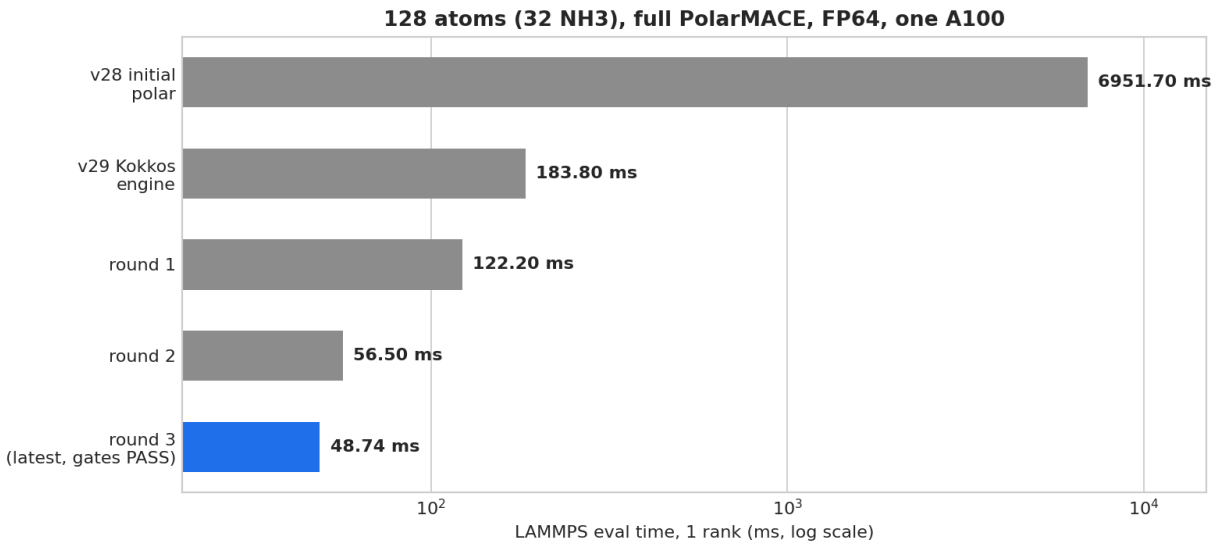


Kernel attribution

最终 GPU-busy 约 43.9 ms，top kernels 仍是 MH-1（约 8.3 ms）、UVU（约 6.4 ms）、 gather（约 3.6 ms）、cuBLAS/external（约 3.8 ms）、e3-linear pack/unpack（约 2.7 ms）。这些是后续继续优化的方向。

5. 实测结果

5.1 128 原子（32 个 NH3 分子）



Speed ladder

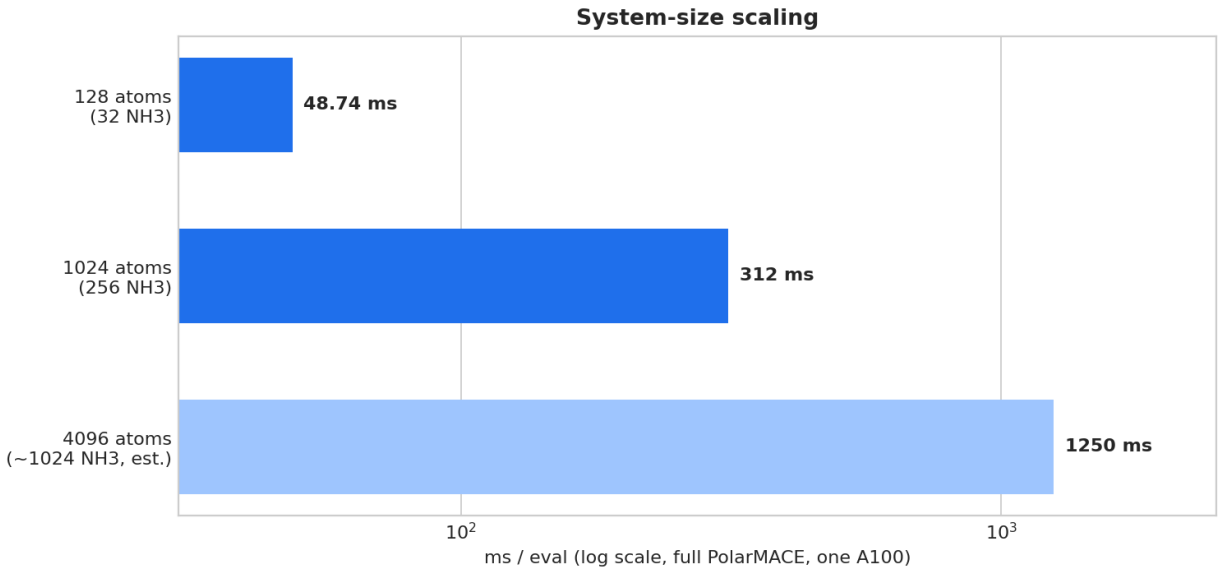
配置	ms/eval
Round-3 最终（latest full-gate PASS）	48.74

同二进制、全部 round-3 开关回退	53.54
同二进制提升	1.0985×
Round-2 验收	56.50
v29 Kokkos 引擎	183.8
v28 初始 polar	6951.7
PyTorch mace_polar 参考	94.0

速度倍率：

基线	倍率
Round-2	1.159×
v29 Kokkos 引擎	3.77×
v28 初始 polar	142.6×
PyTorch 参考	1.93×

5.2 系统尺寸



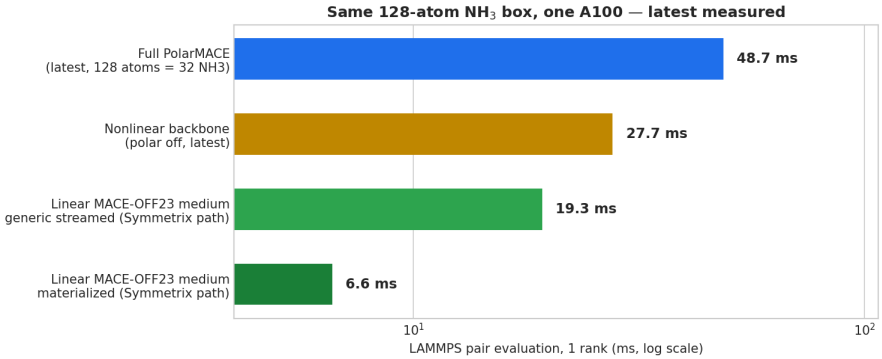
System-size scaling

体系	原子	分子	ms/eval
NH3 1×1×1	128	32	48.74
NH3 2×2×2	1024	256	312.1
NH3 2×4×4	4096	~1024	~1200–1300（外推，未完成实测）

2 ps MD 估算（不含模型加载与 neighbor 重建）：

体系	1 fs	0.5 fs
128 原子（32 NH3）	~1 分 45 秒	~3 分 25 秒
1024 原子（256 NH3）	~10 分 24 秒	~20 分 48 秒
4096 原子（~1024 NH3）	~40 分钟（估）	~80 分钟（估）

5.3 引擎比较（最新测量）



Full PolarMACE: latest 48.74 ms (complete gate suite PASS: module 5-8, 32/32 end-to-end, LAMMPS parity). Backbone polar-off: latest 27.7 ms (full suite PASS). Linear MACE-OFF23 is a smaller, different model; shown for scale only.

Engine comparison

配置（最新测量）	1-rank eval
Full PolarMACE（128 原子 = 32 NH3）	48.74 ms
Nonlinear backbone（polar off）	27.7 ms
Linear MACE-OFF23 medium, materialized（Symmetrix 线性路径；不同模型）	6.6 ms

Linear MACE-OFF23 medium, generic streamed（Symmetrix 通用流式路径；不同模型）	19.3 ms

注意：后两行是同一个 Symmetrix-XL Kokkos 框架下（引擎的线性/通用流式路径）、对一个小得多的线性模型（37 MB、10 元素、r_cut 5 Å）测得的引擎路径时间，不是外部实现的对比。它们说明引擎的线性路径可以很快；Full PolarMACE 是 270 MB、83 元素、r_cut 6 Å、512 通道 非线性 readout，二者不可直接比较。

5.4 数值门（round-3 最终 build）

Numerical gate status of the latest round-3 build

module 5: density / stages	PASS	12 + 11 items
module 6: Coulomb / SCF	PASS	ΔE rel 1.02e-15
module 7: local electron	PASS	16/16, out 4.55e-7
module 8: forces	PASS	FD 5.78e-4, parity 7.19e-7
end-to-end 32 frames	PASS	32/32
LAMMPS 1-rank parity	PASS	dE 2.91e-11 eV, dF 2.63e-14 eV/Å
RBE production force gate	REJECTED	RMS 6.1e-3 eV/Å, 70.4 ms/step

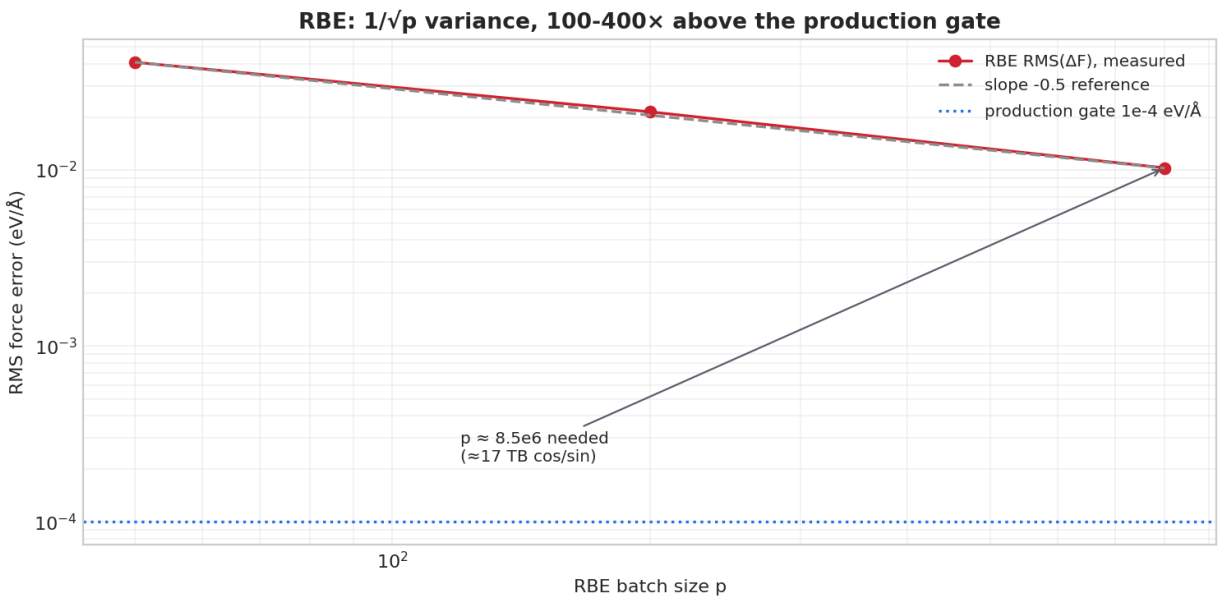
Gate status

门	结果
module 5（密度/阶段）	PASS，12 + 11 项
module 6（Coulomb/SCF）	PASS，p_hat rel 1.27e-15，ΔE rel 1.02e-15，abs 7.77e-16 eV

module 7（局域电子）	PASS，16/16，out 4.55e-7
module 8（力）	PASS，FD 5.783e-4，parity 7.191e-7
end-to-end 32 帧	PASS，32/32
LAMMPS 1-rank parity	PASS，dE 2.910e-11 eV，max dF 2.628e-14 eV/Å

rc 134 出现在每个 gate 的 GATE PASS 之后，是已有的 CUDA teardown abort， 不影响结果。

6. RBE：为什么没有通过



RBE variance

RBE 的 P4 收敛/无偏门 PASS（斜率 −0.499，同 seed 可复现，均值在 3 · SEM 内）， 但生产力/能量精度门 REJECTED：

差异，即使 p→∞ 也未必过门。

- p=800 的 RMS dF 为 6.1e-3 eV/Å，max 3.0e-2，能量噪声 ±0.05 eV；
- 速度 70.4 ms/step，比 exact Ewald（约 53–62 ms）更慢；
- 要降到 1e-4 需要 p≈8.5×10^6，cos/sin 矩阵约 17 TB；
- 全支撑采样与 exact 的硬截断（|k|≤1.8467 1/Å）之间存在 1e-4–1e-3 的系统性

结论：exact full-k Ewald 继续作为生产路径；RBE 保留为 MATOS_RBE_P 实验开关，并作为负结果记录。若未来重启，需要“截断高斯 proposal + 低 |k| 精确 / 高 |k| 随机”的混合方案，而不是简单增大 p。

7. 未完成与不足（诚实清单）

5 ms 是 host/launch gap，其余是 MH-1、UVU、gather、cuBLAS、e3-linear 等 kernel 的实际工作。

access；当前只能 opt-in。

2-rank engine blocker 仍在；本文的 48.74 ms 是单 rank。

只测了速度（同一模型/构建），没有单独的 1024-atom parity gate。

但未进入本文的最终二进制；其余小型 polar kernel 仍有优化空间。

- 1. 30 ms 目标未达到：当前 48.74 ms；20–25 ms 更未达到。剩余 wall 中有约
- 2. e3-linear merged unpack 未修好：多贡献 output block 上有 illegal memory
- 3. CUDA Graph 未做：极化反向有 host↔device 标量往返，暂不可直接 capture。
- 4. MPI H1 2-rank 仍有 blocker：H1 一 rank 修复已被 MPI 工作流接受，但
- 5. 432/1024 原子的完整 gate 未重跑：432 原子仍是 round-2 的数字；1024 原子
- 6. 部分低覆盖率 kernel 仍是串行：polar rev phase and source 的分块代码已写，
- 7. RBE 不能作为加速路径：见第 6 节。

8. 复现指南

8.1 构建

```
cd external-repos/symmetrix-xl/symmetrix
cmake -S ../../lammps-stable_30Sep2026/cmake -B build-kernel-r3 \
  -DCMAKE_BUILD_TYPE=Release -DBUILD_MPI=ON -DPKG_KOKKOS=ON -DSYMMETRIX_KOKKOS=ON \
  -DCMAKE_CXX_STANDARD=20 \
  -DCMAKE_CXX_COMPILER=../../lammps-stable_30Sep2026/lib/kokkos/bin/nvcc_wrapper \
  -DCMAKE_CUDA_HOST_COMPILER=/usr/bin/x86_64-linux-gnu-g++-11 \
  -DKokkos_ENABLE_CUDA=ON -DKokkos_ARCH_AMPERE80=ON \
  -DKokkos_ENABLE_IMPL_VIEW_LEGACY=ON
cmake --build build-kernel-r3 --target lmp --parallel 96
```

8.2 运行

```
export SYMMETRIX_BACKEND=cuda12-sm80
export SYMMETRIX_BACKEND_DESCRIPTOR_PATH=$MLIP/models/mace-polar/backend_cuda12_sm80.json
export
LD_LIBRARY_PATH=/opt/matos-tools/cuda/12.9/lib64:/opt/matos-tools/conda/envs/matos-compute/lib
flock /workspace/group/shared/bza/.tmp/gpu.lock -c \
  "build-kernel-r3/lmp -k on g 1 -in in.nh3_128 -log log.nh3_128"
```

8.3 Round-3 环境开关

开关	默认	作用
MATOS_MH1_CHANNEL_VEC	4	同时设置 MH-1 正/反向 channel vec；1 = round-2
MATOS_MH1_FWD_CHANNEL_VEC	1	前向 vec（4 实测变慢）
MATOS_MH1_REV_CHANNEL_VEC	4	反向 vec
MATOS_MH1_WRITE_THROUGH	1	前向写穿输出
MATOS_MH1_HARMONIC_UNROLL	4	harmonics ILP；1 = 串行
MATOS_MH1_WEIGHT_ZERO_ELIDE	1	去掉 weights_adjoint zero-fill
MATOS_UVU_REV_SWEEP	4	UVU reverse 分块；1 = round-2
MATOS_UVU_FWD_SWEEP	4	UVU forward 分块；1 = round-2
MATOS_AFFINE_LN_PARALLEL	1	affine LN team；0 = 串行
MATOS_CONV_CUTOFF_BACKEND	scalar	chunked 为实验性的两阶段归约
MATOS_E3_LINEAR_MERGED_UNPACK	0	实验性 merged unpack（当前不安全）
MATOS_RBE_P	未设置	启用 RBE 并设置 p（实验性，生产门 REJECTED）

8.4 关键产物

内容	路径
最终报告	docs/results/KERNEL_ROUND3_FINAL.md
最终数据	docs/examples/data/kernel_round3_summary.json
引擎比较数据	docs/examples/data/engine_compare_round3.json
A/B 结果	bench/kernel_round3_2026-10-19/speed_ab_r3final2.json
Gate 日志	bench/kernel_round3_2026-10-19/r3_gate_*.log
CUPTI trace	bench/kernel_round3_2026-10-19/analysis_exact/r3c_full_*

引擎补丁	patches/symmetrix-xl-polar-support.patch

9. 如何续写本文档

这份报告是可续写的 Markdown + Python PDF 生成器：

bash mkdir -p docs/technical/fonts curl -L -o docs/technical/fonts/NotoSansSC-Regular.ttf \ 'https://gh-proxy.com/https://raw.githubusercontent.com/notofonts/noto-cjk/main/Sans/Variable/TTF/Subset/NotoSansSC-VF.ttf'

bash python harness/make_technical_pdf.py 会生成 docs/technical/SYMMETRIX_POLAR_TECHNICAL_REPORT.pdf；

docs/examples/data/kernel_round3_summary.json 和 results/comparison_summary.csv。

- 1. 编辑 docs/technical/TECHNICAL_REPORT.md，在对应章节加入新结果；
- 2. 新图放到 docs/technical/figures/，用 !caption 引用；
- 3. 首次生成前准备中文字体（约 17 MB，不随 git 提交）：
- 4. 重新运行：
- 5. 如果新增结果，请同时更新 docs/results/KERNEL_ROUND3_FINAL.md、

图表生成： 本运行环境没有可调用的 IMAGE2 图像生成接口；文中的示意图和结果图 由 harness/make_technical_figures.py 用 matplotlib 程序化生成，保证可复现、可随数据更新。若后续接入图像生成模型，只需替换同名的 PNG 文件。

附录 A：关键公式速查

q(k)∝ e^-σ_q^2k^2/2

- Ewald k 空间能量：E_k = (2π/V)Σ_k≠0 |ρ(k)|^2/k^2
- GTO 形式因子：ρ(k) 含 exp(-k^2σ^2/2) 与 k^l
- SCF：ρ_n+1=F(ρ_n) 到不动点
- RBE 估计量： E=(1/p)Σ_i f(k_i)/q(k_i)，
- RBE 误差：RMS∝ p^-1/2
- Amdahl：S=1/[(1-p)+p/s]

附录 B：门限与最终数值

门	门限	最终值
module 5 dens/stage	abs 5e-6 / rel 1e-6	dens abs 6.689e-8 / rel 4.218e-8; stage PASS
module 6 dE	rel 1e-6 / abs 5e-6 eV	1.02e-15 / 7.77e-16 eV
module 7 out	1e-6	4.55e-7
module 8 FD / parity	1e-3 / 1e-3	5.783e-4 / 7.191e-7
end-to-end	rel 1e-6, abs 5e-6 eV, dF 1e-4	32/32 PASS

LAMMPS parity	dE 5e-5 eV, dF 1e-4 eV/Å	2.91e-11 eV, 2.63e-14 eV/Å

RBE force	RMS 1e-4 eV/Å	6.1e-3 → REJECTED

附录 C：文件索引

- README.md — 项目入口与最新速度表
- docs/results/KERNEL_ROUND3_FINAL.md — 最终结果（权威）
- docs/testing/GATES.md — 每个门的定义与结果
- docs/testing/BENCHMARKS.md — 测速协议
- docs/theory/ — 性能模型、张量代数、能量模型、MPI H1
- docs/design/ — 各模块设计与 round-3 计划
- docs/examples/data/ — 机器可读结果
- patches/symmetrix-xl-polar-support.patch — 完整引擎补丁